

MLOps: Tổng quan, Định nghĩa và Kiến trúc

Machine Learning Operations (MLOps): Overview, Definition, and Architecture

Dominik Kreuzberger (KIT, Đức) · Niklas Kühl (KIT, Đức) · Sebastian Hirschl (IBM, Đức)

Bài báo này không đại diện cho tuyên bố chính thức của IBM.

Bản dịch tiếng Việt đầy đủ. Các thuật ngữ kỹ thuật được giữ nguyên tiếng Anh trong ngoặc ở lần xuất hiện đầu tiên. Ký hiệu trích dẫn [n] và [α-θ] giữ nguyên theo bản gốc. Hình minh họa được trích trực tiếp từ bài báo gốc.

TÓM TẮT

Mục tiêu cuối cùng của mọi dự án học máy (machine learning – ML) trong công nghiệp là phát triển được các sản phẩm ML và nhanh chóng đưa chúng vào vận hành thực tế (production). Tuy nhiên, việc tự động hóa và vận hành hóa các sản phẩm ML là một thách thức rất lớn, và vì thế nhiều nỗ lực ML đã không đạt được kỳ vọng đặt ra. Hệ hình Machine Learning Operations (MLOps) ra đời để giải quyết vấn đề này. MLOps bao gồm nhiều khía cạnh, chẳng hạn như các thực hành tốt nhất (best practices), các tập hợp khái niệm, và văn hóa phát triển. Tuy vậy, MLOps vẫn còn là một thuật ngữ mơ hồ và những hệ quả của nó đối với giới nghiên cứu cũng như giới chuyên môn còn chưa rõ ràng. Để lấp khoảng trống này, chúng tôi tiến hành một nghiên cứu hỗn hợp phương pháp (mixed-method), bao gồm tổng quan tài liệu, khảo sát công cụ, và phỏng vấn chuyên gia. Từ kết quả của các khảo sát này, chúng tôi đưa ra một bức tranh tổng hợp về các nguyên tắc, thành phần và vai trò cần thiết, cùng với kiến trúc và các luồng công việc đi kèm. Hơn nữa, chúng tôi đề xuất một định nghĩa cho MLOps và nêu bật những thách thức còn bỏ ngỏ trong lĩnh vực này. Cuối cùng, công trình này cung cấp định hướng cho các nhà nghiên cứu và người làm thực tiễn ML muốn tự động hóa và vận hành sản phẩm ML của mình với một tập công nghệ được chỉ định rõ.

TỪ KHÓA

CI/CD, DevOps, Machine Learning, MLOps, Operations, Workflow Orchestration.

1 Giới thiệu

Học máy (ML) đã trở thành một kỹ thuật quan trọng để khai thác tiềm năng của dữ liệu, cho phép các doanh nghiệp trở nên đổi mới hơn [1], hiệu quả hơn [13] và bền vững hơn [22]. Tuy nhiên, mức độ thành công của nhiều ứng dụng ML đưa vào sản xuất trong bối cảnh thực tế lại thấp hơn kỳ vọng [21]. Một số lượng lớn các dự án ML thất bại — với rất nhiều bản chứng minh khái niệm (proof of concept) ML không bao giờ tiến xa được tới production [30]. Từ góc nhìn nghiên cứu, điều này không hề gây ngạc nhiên, bởi cộng đồng ML đã tập trung rất nhiều vào việc xây dựng mô hình ML, nhưng không tập trung vào (a) việc xây dựng những sản phẩm ML sẵn sàng cho production và (b) việc cung cấp sự điều phối cần thiết giữa các thành phần và hạ tầng của hệ thống ML — vốn thường rất phức tạp — bao gồm cả những vai trò cần thiết để tự động hóa và vận hành một hệ thống ML trong môi trường thực tế [35]. Chẳng hạn, trong nhiều ứng dụng công nghiệp, các nhà khoa học dữ liệu vẫn phải quản lý các luồng công việc ML một cách thủ công ở mức độ rất lớn, dẫn tới nhiều vấn đề trong quá trình vận hành giải pháp ML tương ứng [26].

Để giải quyết những vấn đề này, mục tiêu của công trình này là xem xét cách thức các quy trình ML thủ công có thể được tự động hóa và vận hành hóa, sao cho nhiều bản chứng minh khái niệm ML hơn có thể được đưa vào production. Trong công trình này, chúng tôi khảo sát thực hành kỹ thuật ML đang nổi lên mang tên “Machine Learning Operations” — gọi tắt là MLOps — vốn nhằm chính xác vào vấn đề thiết kế và duy trì ML trong môi trường sản xuất. Chúng tôi áp dụng một góc nhìn tổng thể (holistic) nhằm đạt tới một cách hiểu chung về các thành phần, nguyên tắc, vai trò và kiến trúc có liên quan. Mặc dù các nghiên cứu hiện hữu đã soi sáng phần nào một số khía cạnh cụ thể của MLOps, một sự khái niệm hóa, tổng quát hóa và làm rõ mang tính tổng thể về thiết kế hệ thống ML vẫn còn thiếu vắng. Những góc nhìn và quan niệm khác nhau về thuật ngữ “MLOps” có thể dẫn tới hiểu lầm và sai lệch trong giao tiếp, từ đó dẫn tới sai sót trong toàn bộ thiết lập của hệ thống ML. Vì vậy, chúng tôi đặt ra câu hỏi nghiên cứu:

RQ: MLOps là gì?

Để trả lời câu hỏi đó, chúng tôi thực hiện một nghiên cứu hỗn hợp phương pháp nhằm (a) nhận diện các nguyên tắc quan trọng của MLOps, (b) bóc tách các thành phần cốt lõi về mặt chức năng, (c) làm nổi bật các vai trò cần thiết để triển khai MLOps thành công, và (d) rút ra một kiến trúc tổng quát cho thiết kế hệ thống ML. Kết hợp lại, những hiểu biết này dẫn tới một định nghĩa về MLOps, đóng góp vào cách hiểu chung về thuật ngữ và các khái niệm liên quan.

Khi làm như vậy, chúng tôi hy vọng tạo ra tác động tích cực lên các thảo luận học thuật lẫn thực tiễn, bằng cách đưa ra những hướng dẫn rõ ràng cho cả giới chuyên môn lẫn giới nghiên cứu, với trách nhiệm được xác định chính xác. Những hiểu biết này có thể giúp nhiều bản chứng minh khái niệm hơn tiến được vào production nhờ giảm thiểu sai sót trong thiết kế hệ thống, và cuối cùng là cho phép các dự đoán bền vững hơn trong môi trường thực tế.

Phần còn lại của công trình được cấu trúc như sau. Trước hết, chúng tôi trình bày các nền tảng cần thiết và những công trình liên quan trong lĩnh vực. Tiếp theo, chúng tôi giới thiệu tổng quan về phương pháp nghiên cứu được sử dụng, gồm tổng quan tài liệu, khảo sát công cụ và nghiên cứu phỏng vấn. Sau đó, chúng tôi trình bày những hiểu biết thu được từ việc áp dụng phương pháp này và khái niệm hóa chúng bằng cách đưa ra một định nghĩa thống nhất. Chúng tôi kết thúc bài báo bằng một tóm lược ngắn, các hạn chế và hướng đi tiếp theo.


2 Nền tảng về DevOps

Trong quá khứ, nhiều mô hình quy trình phần mềm và phương pháp luận phát triển khác nhau đã xuất hiện trong lĩnh vực kỹ nghệ phần mềm. Những ví dụ nổi bật bao gồm mô hình thác nước (waterfall) [37] và tuyên ngôn agile [5]. Các phương pháp luận đó có mục tiêu tương tự nhau, cụ thể là tạo ra những sản phẩm phần mềm sẵn sàng cho production. Một khái niệm mang tên “DevOps” xuất hiện vào những năm 2008/2009 và hướng tới việc giảm thiểu các vấn đề trong phát triển phần mềm [9,31]. DevOps không chỉ là một phương pháp luận thuần túy, mà đúng hơn nó đại diện cho một hệ hình giải quyết các vấn đề xã hội và kỹ thuật trong những tổ chức làm phát triển phần mềm. Nó có mục tiêu xóa bỏ khoảng cách giữa phát triển (development) và vận hành (operations), đồng thời nhấn mạnh sự cộng tác, giao tiếp và chia sẻ tri thức. Nó bảo đảm tự động hóa thông qua tích hợp liên tục, chuyển giao liên tục và triển khai liên tục (CI/CD), qua đó cho phép các bản phát hành nhanh, thường xuyên và đáng tin cậy. Hơn nữa, nó được thiết kế để bảo đảm kiểm thử liên tục, bảo đảm chất lượng, giám sát và ghi log liên tục, cùng các vòng phản hồi. Do quá trình thương mại hóa DevOps, nhiều công cụ DevOps đã

xuất hiện, có thể phân thành sáu nhóm [23,28]: cộng tác và chia sẻ tri thức (ví dụ Slack, Trello, GitLab wiki), quản lý mã nguồn (ví dụ GitHub, GitLab), quy trình build (ví dụ Maven), tích hợp liên tục (ví dụ Jenkins, GitLab CI), tự động hóa triển khai (ví dụ Kubernetes, Docker), giám sát và ghi log (ví dụ Prometheus, Logstash). Các môi trường đám mây ngày càng được trang bị sẵn bộ công cụ DevOps dùng ngay, được thiết kế cho đám mây, giúp việc tạo ra giá trị trở nên hiệu quả [38]. Với sự dịch chuyển mới mẻ này sang DevOps, lập trình viên phải quan tâm tới những gì mình phát triển, bởi họ cũng phải vận hành chính sản phẩm đó. Như các kết quả thực nghiệm cho thấy, DevOps bảo đảm chất lượng phần mềm tốt hơn [34]. Những người trong ngành, cũng như giới học thuật, đã tích lũy được kho kinh nghiệm phong phú về kỹ nghệ phần mềm khi sử dụng DevOps. Kinh nghiệm đó nay đang được vận dụng để tự động hóa và vận hành hóa ML.

3 Phương pháp nghiên cứu

Để rút ra hiểu biết từ nền tri thức học thuật đồng thời tận dụng chuyên môn của những người làm thực tiễn trong ngành, chúng tôi áp dụng một cách tiếp cận hỗn hợp phương pháp, như được minh họa ở Hình 1. Ở bước đầu tiên, chúng tôi tiến hành một tổng quan tài liệu có cấu trúc [20,43] để có được cái nhìn tổng thể về các nghiên cứu liên quan. Tiếp đó, chúng tôi rà soát các công cụ hỗ trợ liên quan trong lĩnh vực MLOps nhằm hiểu rõ hơn về các thành phần kỹ thuật có liên quan. Cuối cùng, chúng tôi tiến hành các cuộc phỏng vấn bán cấu trúc [33,39] với các chuyên gia từ những lĩnh vực khác nhau. Trên cơ sở đó, chúng tôi khái niệm hóa thuật ngữ “MLOps” và triển khai chi tiết các phát hiện của mình bằng cách tổng hợp tài liệu và phỏng vấn trong chương tiếp theo (“Kết quả”).



Hình 1. Tổng quan phương pháp nghiên cứu

3.1 Tổng quan tài liệu

Để bảo đảm rằng kết quả của chúng tôi dựa trên tri thức khoa học, chúng tôi tiến hành một tổng quan tài liệu có hệ thống theo phương pháp của Webster và Watson [43] và Kitchenham cùng cộng sự [20]. Sau một lượt tìm kiếm thăm dò ban đầu, chúng tôi xác định truy vấn tìm kiếm như sau:

((("DevOps" OR "CI/CD" OR "Continuous Integration" OR "Continuous Delivery" OR "Continuous Deployment") AND "Machine Learning") OR "MLOps" OR "CD4ML")

Chúng tôi truy vấn các cơ sở dữ liệu khoa học Google Scholar, Web of Science, Science Direct, Scopus và thư viện điện tử của Association for Information Systems. Cần lưu ý rằng việc sử dụng DevOps cho ML, MLOps, và các thực hành liên tục kết hợp với ML là một lĩnh vực tương đối mới trong tài liệu học thuật. Do đó, chỉ có một số ít nghiên cứu đã qua bình duyệt là có sẵn tại thời điểm thực hiện nghiên cứu này. Dù vậy, để thu thập kinh nghiệm trong lĩnh vực này, phạm vi tìm kiếm bao gồm cả tài liệu chưa qua bình duyệt. Việc tìm kiếm được thực hiện vào tháng 5 năm 2021 và thu về 1.864 bài báo. Trong số đó, chúng tôi sàng lọc chi tiết 194 bài. Từ nhóm này, 27 bài báo được chọn dựa trên các tiêu chí lựa chọn và loại trừ của chúng tôi (ví dụ: thuật ngữ MLOps hoặc DevOps và CI/CD kết hợp với ML được mô tả chi tiết, bài báo được viết bằng tiếng Anh, v.v.). Cả 27 bài báo này đều đã qua bình duyệt.

3.2 Khảo sát công cụ

Sau khi rà soát 27 bài báo và tám cuộc phỏng vấn, nhiều công cụ mã nguồn mở, framework và dịch vụ ML đám mây thương mại đã được nhận diện. Các công cụ, framework và dịch vụ ML này được rà soát nhằm hiểu rõ các thành phần kỹ thuật cấu thành nên chúng. Tổng quan về các công cụ được nhận diện được trình bày trong Bảng 1 của Phụ lục.

3.3 Nghiên cứu phỏng vấn

Để trả lời các câu hỏi nghiên cứu bằng hiểu biết từ thực tiễn, chúng tôi tiến hành phỏng vấn chuyên gia bán cấu trúc theo Myers và Newman [33]. Một khía cạnh quan trọng trong thiết kế nghiên cứu phỏng vấn chuyên gia là lựa chọn cỡ mẫu phù hợp [8]. Chúng tôi áp dụng cách tiếp cận lấy mẫu lý thuyết (theoretical sampling) [12], cho phép chúng tôi chọn những đối tác phỏng vấn giàu kinh nghiệm nhằm thu được dữ liệu chất lượng cao. Dữ liệu như vậy có thể mang lại những hiểu biết có ý nghĩa với một số lượng phỏng vấn hạn chế. Để có được nhóm mẫu phù hợp và những hiểu biết đáng tin cậy, chúng tôi sử dụng LinkedIn — một mạng xã hội dành cho giới chuyên môn — để xác định những chuyên gia ML giàu kinh nghiệm, có hiểu biết sâu sắc về MLOps trên phạm vi toàn cầu. Để thu được hiểu biết từ nhiều góc nhìn khác nhau, chúng tôi chọn các đối tác phỏng vấn từ những tổ chức và ngành nghề khác nhau, những quốc gia và quốc tịch khác nhau, cũng như khác nhau về giới tính. Các cuộc phỏng vấn được tiến hành cho tới khi không còn phạm trù và khái niệm mới nào xuất hiện trong quá trình phân tích dữ liệu. Tổng cộng, chúng tôi thực hiện tám cuộc phỏng vấn với các chuyên gia ($\alpha - \theta$), thông tin chi tiết được trình bày trong Bảng 2 của Phụ lục. Theo Glaser và Strauss [5, tr.61], giai đoạn này được gọi là “bão hòa lý thuyết” (theoretical saturation). Tất cả các cuộc phỏng vấn được tiến hành trong khoảng từ tháng 6 đến tháng 8 năm 2021.


Về thiết kế phỏng vấn, chúng tôi chuẩn bị một bản hướng dẫn bán cấu trúc với nhiều câu hỏi, được ghi lại dưới dạng kịch bản phỏng vấn [33]. Trong quá trình phỏng vấn, kỹ thuật “soft laddering” được sử dụng với các câu hỏi “như thế nào” và “tại sao” nhằm dò tìm chuỗi phương tiện – mục đích (means-end chain) của người được phỏng vấn [39]. Cách tiếp cận phương pháp luận này cho phép chúng tôi thu được hiểu biết bổ sung về trải nghiệm của người được phỏng vấn khi cần thiết. Tất cả các cuộc phỏng vấn đều được ghi âm và sau đó được gỡ băng. Để đánh giá các bản gỡ băng phỏng vấn, chúng tôi sử dụng một lược đồ mã hóa mở (open coding) [8].

4 Kết quả

Chúng tôi áp dụng phương pháp đã mô tả và cấu trúc các hiểu biết thu được thành: phần trình bày các nguyên tắc quan trọng, sự hiện thực hóa các nguyên tắc đó thành các thành phần, mô tả các vai trò cần thiết, cũng như một đề xuất về kiến trúc và luồng công việc hình thành từ sự kết hợp của những khía cạnh này. Cuối cùng, chúng tôi rút ra sự khái niệm hóa của thuật ngữ và đưa ra một định nghĩa về MLOps.

4.1 Các nguyên tắc

Một nguyên tắc (principle) được hiểu là một chân lý tổng quát hoặc cơ bản, một giá trị, hoặc một chỉ dẫn cho hành vi. Trong bối cảnh MLOps, một nguyên tắc là chỉ dẫn về cách thức mọi thứ nên được hiện thực hóa trong MLOps, và có liên hệ chặt chẽ với thuật ngữ “thực hành tốt nhất” (best practices) trong giới chuyên môn. Dựa trên phương pháp đã trình bày, chúng tôi nhận diện được chín nguyên tắc cần thiết để hiện thực hóa MLOps. Hình 2 minh họa các nguyên tắc này và liên kết chúng với những thành phần mà chúng gắn với.



Hình 2. Hiện thực hóa các nguyên tắc bên trong các thành phần kỹ thuật

P1 Tự động hóa CI/CD. Tự động hóa CI/CD cung cấp tích hợp liên tục, chuyển giao liên tục và triển khai liên tục. Nó thực hiện các bước build, test, delivery và deploy. Nó cung cấp phản hồi nhanh cho lập trình viên về việc thành công hay thất bại của một số bước nhất định, qua đó tăng năng suất tổng thể [15,17,26,27,35,42,46] $[\alpha, \beta, \theta]$.

P2 Điều phối luồng công việc (Workflow orchestration). Điều phối luồng công việc phối hợp các tác vụ của một pipeline luồng công việc ML theo các đồ thị có hướng không chu trình (DAG). Các DAG xác định thứ tự thực thi tác vụ bằng cách xem xét các quan hệ và phụ thuộc [14,17,26,32,40,41] $[\alpha, \beta, \gamma, \delta, \zeta, \eta]$.

P3 Khả năng tái lập (Reproducibility). Khả năng tái lập là khả năng tái hiện một thí nghiệm ML và thu được đúng cùng một kết quả [14,32,40,46] $[\alpha, \beta, \delta, \epsilon, \eta]$.

P4 Quản lý phiên bản (Versioning). Quản lý phiên bản bảo đảm việc đánh phiên bản cho dữ liệu, mô hình và mã nguồn, nhằm cho phép không chỉ khả năng tái lập mà còn cả khả năng truy vết (phục vụ mục đích tuân thủ và kiểm toán) [14,32,40,46] $[\alpha, \beta, \delta, \epsilon, \eta]$.

P5 Cộng tác (Collaboration). Cộng tác bảo đảm khả năng làm việc cộng tác trên dữ liệu, mô hình và mã nguồn. Bên cạnh khía cạnh kỹ thuật, nguyên tắc này nhấn mạnh một văn hóa làm việc mang tính cộng tác và giao tiếp, hướng tới việc giảm bớt các ốc đảo chuyên môn (domain silos) giữa những vai trò khác nhau [14,26,40] $[\alpha, \delta, \theta]$.

P6 Huấn luyện và đánh giá ML liên tục. Huấn luyện liên tục nghĩa là huấn luyện lại mô hình ML theo chu kỳ dựa trên dữ liệu đặc trưng (feature data) mới. Huấn luyện liên tục được kích hoạt nhờ sự hỗ trợ của một thành phần giám sát, một vòng phản hồi và một pipeline luồng công việc ML tự động. Huấn luyện liên tục luôn bao gồm một lượt đánh giá để thẩm định sự thay đổi về chất lượng mô hình [10,17,19,46] $[\beta, \delta, \eta, \theta]$.

P7 Theo dõi/ghi log siêu dữ liệu ML. Siêu dữ liệu (metadata) được theo dõi và ghi log cho từng tác vụ luồng công việc ML được điều phối. Việc theo dõi và ghi log siêu dữ liệu là bắt buộc đối với mỗi lượt lặp của công việc huấn luyện (ví dụ ngày giờ huấn luyện, thời lượng, v.v.), bao gồm cả siêu dữ liệu riêng của mô hình — ví dụ các tham số đã dùng và các chỉ số hiệu năng thu được, cũng như nguồn gốc mô hình (model lineage): dữ liệu và mã nguồn đã dùng — nhằm bảo đảm khả năng truy vết đầy đủ của các lượt thí nghiệm [26,27,29,32,35] $[\alpha, \beta, \delta, \epsilon, \zeta, \eta, \theta]$.

P8 Giám sát liên tục. Giám sát liên tục hàm ý việc đánh giá theo chu kỳ đối với dữ liệu, mô hình, mã nguồn, tài nguyên hạ tầng và hiệu năng phục vụ mô hình (ví dụ độ chính xác dự đoán) nhằm phát hiện những lỗi tiềm ẩn hoặc những thay đổi ảnh hưởng tới chất lượng sản phẩm [4,7,10,27,29,42,46] $[\alpha, \beta, \gamma, \delta, \epsilon, \zeta, \eta]$.

P9 Các vòng phản hồi (Feedback loops). Cần có nhiều vòng phản hồi để đưa những hiểu biết từ bước đánh giá chất lượng trở lại quá trình phát triển hoặc kỹ nghệ (ví dụ một vòng phản hồi từ giai đoạn kỹ nghệ mô hình thực nghiệm quay về giai đoạn kỹ nghệ đặc trưng trước đó). Một vòng phản hồi khác là cần thiết từ thành phần giám sát (ví dụ quan sát hiệu năng phục vụ mô hình) tới bộ lập lịch (scheduler) nhằm cho phép việc huấn luyện lại [4,6,7,17,27,46] $[\alpha, \beta, \delta, \zeta, \eta, \theta]$.

4.2 Các thành phần kỹ thuật

Sau khi nhận diện các nguyên tắc cần được tích hợp vào MLOps, giờ đây chúng tôi trình bày chi tiết các thành phần cụ thể và cách hiện thực hóa chúng trong thiết kế hệ thống ML. Dưới đây, các thành phần được liệt kê và mô tả một cách tổng quát cùng với những chức năng thiết yếu của chúng. Các tham chiếu trong ngoặc chỉ tới những nguyên tắc tương ứng mà thành phần kỹ thuật đó hiện thực hóa.

C1 Thành phần CI/CD (P1, P6, P9). Thành phần CI/CD bảo đảm tích hợp liên tục, chuyên giao liên tục và triển khai liên tục. Nó đảm nhiệm các bước build, test, delivery và deploy. Nó cung cấp phản hồi nhanh cho lập trình viên về việc thành công hay thất bại của một số bước nhất định, qua đó tăng năng suất tổng thể [10,15,17,26,35,46] $[\alpha, \beta, \gamma, \epsilon, \zeta, \eta]$. Ví dụ là Jenkins [17,26] và GitHub Actions (η).

C2 Kho mã nguồn (P4, P5). Kho mã nguồn bảo đảm việc lưu trữ và đánh phiên bản mã nguồn. Nó cho phép nhiều lập trình viên commit và merge mã của họ [17,25,42,44,46] $[\alpha, \beta, \gamma, \zeta, \theta]$. Ví dụ bao gồm Bitbucket [11] $[\zeta]$, GitLab [11,17] $[\zeta]$, GitHub [25] $[\zeta, \eta]$ và Gitea [46].

C3 Thành phần điều phối luồng công việc (P2, P3, P6). Thành phần điều phối luồng công việc cung cấp khả năng điều phối tác vụ của một luồng công việc ML thông qua đồ thị có hướng không chu trình (DAG). Các đồ thị này biểu diễn thứ tự thực thi và việc sử dụng artifact của từng bước trong luồng công việc [26,32,35,40,41,46] [α , β , γ , δ , ϵ , ζ , η]. Ví dụ bao gồm Apache Airflow [α , ζ], Kubeflow Pipelines [ζ], Luigi [ζ], AWS SageMaker Pipelines [β] và Azure Pipelines [ϵ].

C4 Hệ thống feature store (P3, P4). Hệ thống feature store bảo đảm việc lưu trữ tập trung các đặc trưng thường dùng. Nó được cấu hình với hai cơ sở dữ liệu: một cơ sở dữ liệu đóng vai trò feature store ngoại tuyến (offline) để phục vụ đặc trưng với độ trễ bình thường cho việc thực nghiệm, và một cơ sở dữ liệu đóng vai trò store trực tuyến (online) để phục vụ đặc trưng với độ trễ thấp cho các dự đoán trong production [10,14] [α , β , ζ , ϵ , θ]. Ví dụ bao gồm Google Feast [ζ], Amazon AWS Feature Store [β , ζ], Tecton.ai và Hopsworx.ai [ζ]. Đây là nơi phần lớn dữ liệu dùng để huấn luyện mô hình ML sẽ đến từ đó. Ngoài ra, dữ liệu cũng có thể đến trực tiếp từ bất kỳ dạng kho dữ liệu nào.

C5 Hạ tầng huấn luyện mô hình (P6). Hạ tầng huấn luyện mô hình cung cấp các tài nguyên tính toán nền tảng, ví dụ CPU, RAM và GPU. Hạ tầng được cung cấp có thể là phân tán hoặc không phân tán. Nhìn chung, một hạ tầng có khả năng mở rộng và phân tán được khuyến nghị [7,10,24–26,29,40,45,46] [δ , ζ , η , θ]. Ví dụ bao gồm máy cục bộ (không mở rộng được) hoặc tính toán đám mây [7] [η , θ], cũng như tính toán không phân tán hoặc phân tán (nhiều nút worker) [25,27]. Các framework hỗ trợ tính toán là Kubernetes [η , θ] và Red Hat OpenShift [γ].

C6 Model registry (P3, P4). Model registry lưu trữ tập trung các mô hình ML đã huấn luyện cùng với siêu dữ liệu của chúng. Nó có hai chức năng chính: lưu trữ artifact ML và lưu trữ siêu dữ liệu ML (xem C7) [4,6,14,17,26,27] [α , β , γ , ϵ , ζ , η , θ]. Ví dụ về kho lưu trữ nâng cao bao gồm MLflow [α , η , ζ], AWS SageMaker Model Registry [ζ], Microsoft Azure ML Model Registry [ζ] và Neptune.ai [α]. Ví dụ về kho lưu trữ đơn giản bao gồm Microsoft Azure Storage, Google Cloud Storage và Amazon AWS S3 [17].

C7 Kho siêu dữ liệu ML (P4, P7). Kho siêu dữ liệu ML cho phép theo dõi nhiều loại siêu dữ liệu khác nhau, ví dụ cho từng tác vụ của pipeline luồng công việc ML được điều phối. Một kho siêu dữ liệu khác có thể được cấu hình bên trong model registry để theo dõi và ghi log siêu dữ liệu của từng công việc huấn luyện (ví dụ ngày giờ huấn luyện, thời lượng, v.v.), bao gồm cả siêu dữ liệu riêng của mô hình — ví dụ các tham số đã dùng và các chỉ số hiệu năng thu được, nguồn gốc mô hình: dữ liệu và mã nguồn đã dùng [14,25–27,32] [α , β , δ , ζ , θ]. Ví dụ bao gồm các bộ điều phối có sẵn kho siêu dữ liệu tích hợp để theo dõi từng bước của pipeline thí nghiệm [α] như Kubeflow Pipelines [α , ζ], AWS SageMaker Pipelines [α , ζ], Azure ML và IBM Watson Studio [γ]. MLflow cung cấp một kho siêu dữ liệu nâng cao kết hợp với model registry [32,35].

C8 Thành phần phục vụ mô hình (P1). Thành phần phục vụ mô hình (model serving) có thể được cấu hình cho những mục đích khác nhau. Ví dụ là suy luận trực tuyến (online inference) cho dự đoán thời gian thực, hoặc suy luận theo lô (batch inference) cho dự đoán sử dụng khối lượng lớn dữ liệu đầu vào. Việc phục vụ có thể được cung cấp, ví dụ, qua một REST API. Ở lớp hạ tầng nền tảng, một hạ tầng phục vụ mô hình có khả năng mở rộng và phân tán được khuyến nghị [7,11,25,40,45,46] [α , β , δ , ζ , η , θ]. Một ví dụ về cấu hình thành phần phục vụ mô hình là sử dụng công nghệ Kubernetes và Docker để đóng gói mô hình ML vào container, kết hợp với một framework ứng dụng web Python như Flask [17] cùng một API để phục vụ [α]. Các framework khác được Kubernetes hỗ trợ là KServing của Kubeflow [α], TensorFlow Serving và Seldon.io

serving [40]. Việc suy luận cũng có thể được hiện thực bằng Apache Spark cho dự đoán theo lô [0]. Ví dụ về dịch vụ đám mây bao gồm Microsoft Azure ML REST API [ε], AWS SageMaker Endpoints [α, β], IBM Watson Studio [γ] và dịch vụ dự đoán Google Vertex AI [δ].

C9 Thành phần giám sát (P8, P9). Thành phần giám sát đảm nhiệm việc giám sát liên tục hiệu năng phục vụ mô hình (ví dụ độ chính xác dự đoán). Ngoài ra, việc giám sát hạ tầng ML, CI/CD và điều phối cũng là cần thiết [7,10,17,26,29,36,46] [α, ζ, η, θ]. Ví dụ bao gồm Prometheus kết hợp Grafana [η, ζ], bộ ELK (Elasticsearch, Logstash và Kibana) [α, η, ζ], và đơn giản là TensorBoard [0]. Ví dụ về các nền tảng có sẵn năng lực giám sát tích hợp là Kubeflow [0], MLflow [η] và AWS SageMaker model monitor hoặc CloudWatch [ζ].

4.3 Các vai trò

Sau khi mô tả các nguyên tắc và sự hiện thực hóa của chúng thành các thành phần, tiếp theo chúng tôi nhận diện những vai trò cần thiết để hiện thực hóa MLOps. MLOps là một quá trình nhóm mang tính liên ngành, và sự tương tác giữa các vai trò khác nhau là yếu tố then chốt để thiết kế, quản lý, tự động hóa và vận hành một hệ thống ML trong production. Dưới đây, từng vai trò, mục đích và các nhiệm vụ liên quan được mô tả ngắn gọn:

R1 Bên liên quan phía nghiệp vụ (vai trò tương tự: Product Owner, Project Manager). Bên liên quan phía nghiệp vụ xác định mục tiêu kinh doanh cần đạt được bằng ML và đảm nhiệm phần giao tiếp của mảng nghiệp vụ, ví dụ trình bày lợi tức đầu tư (ROI) mà sản phẩm ML tạo ra [17,24,26] [α, β, δ, θ].

R2 Kiến trúc sư giải pháp (vai trò tương tự: IT Architect). Kiến trúc sư giải pháp thiết kế kiến trúc và xác định các công nghệ sẽ sử dụng, sau một quá trình đánh giá kỹ lưỡng [17,27] [α, ζ].

R3 Nhà khoa học dữ liệu (vai trò tương tự: ML Specialist, ML Developer). Nhà khoa học dữ liệu chuyển bài toán nghiệp vụ thành bài toán ML và đảm nhiệm phần kỹ nghệ mô hình, bao gồm việc lựa chọn thuật toán và siêu tham số cho hiệu năng tốt nhất [7,14,26,29] [α, β, γ, δ, ε, ζ, η, θ].


R4 Kỹ sư dữ liệu (vai trò tương tự: DataOps Engineer). Kỹ sư dữ liệu xây dựng và quản lý các pipeline dữ liệu và kỹ nghệ đặc trưng. Hơn nữa, vai trò này bảo đảm việc nạp dữ liệu (data ingestion) đúng cách vào các cơ sở dữ liệu của hệ thống feature store [14,29,41] [α, β, γ, δ, ε, ζ, η, θ].

R5 Kỹ sư phần mềm. Kỹ sư phần mềm áp dụng các mẫu thiết kế phần mềm, các hướng dẫn viết mã được thừa nhận rộng rãi và các thực hành tốt nhất để biến bài toán ML thô thành một sản phẩm được kỹ nghệ hóa tốt [29] [α, γ].

R6 Kỹ sư DevOps. Kỹ sư DevOps bắc cầu giữa phát triển và vận hành, bảo đảm việc tự động hóa CI/CD đúng cách, điều phối luồng công việc ML, triển khai mô hình lên production và giám sát [14–16,26] [α, β, γ, ε, ζ, η, θ].

R7 Kỹ sư ML / Kỹ sư MLOps. Kỹ sư ML hay kỹ sư MLOps kết hợp các khía cạnh của nhiều vai trò khác nhau và do đó có tri thức liên lĩnh vực. Vai trò này tích hợp kỹ năng của nhà khoa học dữ liệu, kỹ sư dữ liệu, kỹ sư phần mềm, kỹ sư DevOps và kỹ sư backend (xem Hình 3). Vai trò liên lĩnh vực này xây dựng và vận hành hạ tầng ML, quản lý các pipeline luồng công việc

ML tự động và việc triển khai mô hình lên production, đồng thời giám sát cả mô hình lẫn hạ tầng ML [14,17,26,29] $[\alpha, \beta, \gamma, \delta, \epsilon, \zeta, \eta, \theta]$.




Hình 3. Các vai trò và phân giao nhau giữa chúng đóng góp vào hệ hình MLOps

5 Kiến trúc và luồng công việc

Trên cơ sở các nguyên tắc, thành phần và vai trò đã nhận diện, chúng tôi rút ra một kiến trúc MLOps đầu-cuối tổng quát nhằm cung cấp định hướng phù hợp cho các nhà nghiên cứu và người làm thực tiễn ML. Kiến trúc này được minh họa ở Hình 4. Bên cạnh đó, chúng tôi mô tả các luồng công việc, tức là trình tự mà các tác vụ khác nhau được thực thi trong các giai đoạn khác nhau. Sản phẩm thiết kế này được xây dựng theo hướng độc lập với công nghệ (technology-agnostic). Do đó, các nhà nghiên cứu và người làm thực tiễn ML có thể lựa chọn những công nghệ và framework phù hợp nhất với nhu cầu của mình.

Như minh họa ở Hình 4, chúng tôi mô tả một quy trình đầu-cuối, từ khởi tạo dự án MLOps cho tới phục vụ mô hình. Nó bao gồm: (A) các bước khởi tạo dự án MLOps; (B) pipeline kỹ nghệ đặc trưng, bao gồm việc nạp dữ liệu vào feature store; (C) giai đoạn thực nghiệm; và (D) pipeline luồng công việc ML tự động cho tới khâu phục vụ mô hình.



Hình 4. Kiến trúc và luồng công việc MLOps đầu-cuối với các thành phần chức năng và vai trò

(A) Khởi tạo dự án MLOps. (1) Bên liên quan phía nghiệp vụ (R1) phân tích hoạt động kinh doanh và nhận diện một bài toán nghiệp vụ tiềm năng có thể giải quyết bằng ML. (2) Kiến trúc sư giải pháp (R2) xác định thiết kế kiến trúc cho toàn bộ hệ thống ML và quyết định các công nghệ sẽ sử dụng sau khi đánh giá kỹ lưỡng. (3) Nhà khoa học dữ liệu (R3) rút ra bài toán ML — chẳng hạn nên dùng hồi quy hay phân loại — từ mục tiêu nghiệp vụ. (4) Kỹ sư dữ liệu (R4) và nhà khoa học dữ liệu (R3) phối hợp với nhau để hiểu dữ liệu nào là cần thiết nhằm giải quyết bài toán. (5) Khi các câu trả lời đã rõ ràng, kỹ sư dữ liệu (R4) và nhà khoa học dữ liệu (R3) cùng nhau xác định vị trí các nguồn dữ liệu thô để phân tích dữ liệu ban đầu. Họ kiểm tra phân phối và chất lượng của dữ liệu, cũng như thực hiện các kiểm tra tính hợp lệ. Hơn nữa, họ bảo đảm rằng dữ liệu đến từ các nguồn đã được gán nhãn, nghĩa là thuộc tính mục tiêu đã được biết, bởi đây là yêu cầu bắt buộc đối với ML có giám sát. Trong ví dụ này, các nguồn dữ liệu đã có sẵn dữ liệu được gán nhãn, do bước gán nhãn đã được thực hiện trong một quy trình thượng nguồn.

(B1) Yêu cầu cho pipeline kỹ nghệ đặc trưng. Các đặc trưng (features) là những thuộc tính liên quan cần thiết cho việc huấn luyện mô hình. Sau khi có hiểu biết ban đầu về dữ liệu thô và phân tích dữ liệu ban đầu, các yêu cầu cơ bản cho pipeline kỹ nghệ đặc trưng được xác định như sau: (6) Kỹ sư dữ liệu (R4) xác định các quy tắc biến đổi dữ liệu (chuẩn hóa, tổng hợp) và các quy tắc làm sạch để đưa dữ liệu về định dạng sử dụng được. (7) Nhà khoa học dữ liệu (R3) và kỹ sư dữ liệu (R4) cùng nhau xác định các quy tắc kỹ nghệ đặc trưng, chẳng hạn việc tính toán những đặc trưng mới và nâng cao hơn dựa trên các đặc trưng khác. Những quy tắc được định nghĩa ban đầu này phải được nhà khoa học dữ liệu (R3) điều chỉnh lặp đi lặp lại, dựa trên phản hồi đến từ giai đoạn kỹ nghệ mô hình thực nghiệm hoặc từ thành phần giám sát đang quan sát hiệu năng mô hình.

(B2) Pipeline kỹ nghệ đặc trưng. Các yêu cầu được định nghĩa ban đầu cho pipeline kỹ nghệ đặc trưng được kỹ sư dữ liệu (R4) và kỹ sư phần mềm (R5) tiếp nhận làm điểm khởi đầu để xây dựng nguyên mẫu của pipeline kỹ nghệ đặc trưng. Các yêu cầu và quy tắc được định nghĩa ban đầu sẽ được cập nhật theo phản hồi lặp đến từ giai đoạn kỹ nghệ mô hình thực nghiệm hoặc từ thành phần giám sát đang quan sát hiệu năng của mô hình trong production. Như một yêu cầu nền tảng, kỹ sư dữ liệu (R4) xác định mã nguồn cần thiết cho thành phần CI/CD (C1) và thành phần điều phối (C3) nhằm bảo đảm việc điều phối tác vụ của pipeline kỹ nghệ đặc trưng. Vai trò này cũng xác định cấu hình tài nguyên hạ tầng bên dưới. (8) Trước hết, pipeline kỹ nghệ đặc trưng kết nối tới dữ liệu thô, vốn có thể là (chẳng hạn) dữ liệu luồng (streaming), dữ liệu theo lô tĩnh, hoặc dữ liệu từ bất kỳ kho lưu trữ đám mây nào. (9) Dữ liệu sẽ được trích xuất từ các nguồn dữ liệu. (10) Quá trình tiền xử lý dữ liệu bắt đầu bằng các tác vụ biến đổi và làm sạch dữ liệu. Artifact quy tắc biến đổi được định nghĩa ở giai đoạn thu thập yêu cầu đóng vai trò đầu vào cho tác vụ này, và mục tiêu chính của tác vụ này là đưa dữ liệu về định dạng sử dụng được. Các quy tắc biến đổi này được cải tiến liên tục dựa trên phản hồi. (11) Tác vụ kỹ nghệ đặc trưng tính toán những đặc trưng mới và nâng cao hơn dựa trên các đặc trưng khác. Các quy tắc kỹ nghệ đặc trưng đã định nghĩa trước đóng vai trò đầu vào cho tác vụ này. Những quy tắc kỹ nghệ đặc trưng này được cải tiến liên tục dựa trên phản hồi. (12) Cuối cùng, một công việc nạp dữ liệu (data ingestion job) tải dữ liệu theo lô hoặc dữ liệu luồng vào hệ thống feature store (C4). Đích đến có thể là cơ sở dữ liệu offline hoặc online (hoặc bất kỳ dạng kho dữ liệu nào).

(C) Thực nghiệm. Phần lớn các tác vụ trong giai đoạn thực nghiệm do nhà khoa học dữ liệu (R3) dẫn dắt. Nhà khoa học dữ liệu được kỹ sư phần mềm (R5) hỗ trợ. (13) Nhà khoa học dữ liệu (R3) kết nối tới hệ thống feature store (C4) để phân tích dữ liệu. (Ngoài ra, nhà khoa học dữ liệu (R3) cũng có thể kết nối trực tiếp tới dữ liệu thô để phân tích ban đầu.) Trong trường hợp cần bất kỳ điều chỉnh dữ liệu nào, nhà khoa học dữ liệu (R3) báo cáo những thay đổi cần thiết ngược trở lại vùng kỹ nghệ dữ liệu (vòng phản hồi).

(14) Tiếp đó, cần thực hiện việc chuẩn bị và kiểm định dữ liệu đến từ hệ thống feature store. Tác vụ này cũng bao gồm việc tạo tập dữ liệu chia tách huấn luyện và kiểm thử (train/test split). (15) Nhà khoa học dữ liệu (R3) ước lượng thuật toán và siêu tham số cho hiệu năng tốt nhất, sau đó quá trình huấn luyện mô hình được kích hoạt với dữ liệu huấn luyện (C5). Kỹ sư phần mềm (R5) hỗ trợ nhà khoa học dữ liệu (R3) trong việc tạo ra mã huấn luyện mô hình được kỹ nghệ hóa tốt. (16) Các tham số mô hình khác nhau được kiểm thử và kiểm định một cách tương tác qua nhiều vòng huấn luyện. Khi các chỉ số hiệu năng cho thấy kết quả tốt, quá trình huấn luyện lặp sẽ dừng lại. Các tham số mô hình cho hiệu năng tốt nhất được xác định thông qua việc tinh chỉnh tham số. Tác vụ huấn luyện mô hình và tác vụ kiểm định mô hình sau đó được lặp lại

nhiều lần; cùng với nhau, các tác vụ này có thể được gọi là “kỹ nghệ mô hình” (model engineering). Kỹ nghệ mô hình nhằm xác định thuật toán và siêu tham số cho hiệu năng tốt nhất đối với mô hình. (17) Nhà khoa học dữ liệu (R3) xuất mô hình và commit mã nguồn vào kho lưu trữ.

Như một yêu cầu nền tảng, hoặc kỹ sư DevOps (R6) hoặc kỹ sư ML (R7) xác định mã nguồn cho pipeline luồng công việc ML tự động (C2) và commit nó vào kho lưu trữ. Một khi nhà khoa học dữ liệu (R3) commit một mô hình ML mới, hoặc kỹ sư DevOps (R6) và kỹ sư ML (R7) commit mã pipeline luồng công việc ML mới vào kho lưu trữ, thành phần CI/CD (C1) sẽ phát hiện mã nguồn đã cập nhật và tự động kích hoạt pipeline CI/CD thực hiện các bước build, test và delivery. Bước build tạo ra các artifact chứa mô hình ML và các tác vụ của pipeline luồng công việc ML. Bước test kiểm định mô hình ML và mã pipeline luồng công việc ML. Bước delivery đẩy (các) artifact đã được đánh phiên bản — chẳng hạn như image — lên kho artifact (ví dụ image registry).

(D) Pipeline luồng công việc ML tự động. Kỹ sư DevOps (R6) và kỹ sư ML (R7) đảm nhiệm việc quản lý pipeline luồng công việc ML tự động. Họ cũng quản lý hạ tầng huấn luyện mô hình bên dưới dưới dạng tài nguyên phần cứng và các framework hỗ trợ tính toán như Kubernetes (C5). Thành phần điều phối luồng công việc (C3) điều phối các tác vụ của pipeline luồng công việc ML tự động. Với mỗi tác vụ, các artifact cần thiết (ví dụ image) được kéo về từ kho artifact (ví dụ image registry). Mỗi tác vụ có thể được thực thi trong một môi trường cô lập (ví dụ container). Cuối cùng, thành phần điều phối luồng công việc (C3) thu thập siêu dữ liệu cho từng tác vụ dưới dạng log, thời gian hoàn thành, v.v.

Một khi pipeline luồng công việc ML tự động được kích hoạt, mỗi tác vụ sau đây được quản lý một cách tự động: (18) tự động kéo về các đặc trưng đã được đánh phiên bản từ hệ thống feature store (trích xuất dữ liệu). Tùy vào tình huống sử dụng, các đặc trưng được trích xuất từ cơ sở dữ liệu offline hoặc online (hoặc bất kỳ dạng kho dữ liệu nào). (19) Tự động chuẩn bị và kiểm định dữ liệu; ngoài ra, việc chia tách train/test cũng được xác định tự động. (20) Tự động huấn luyện mô hình lần cuối trên dữ liệu mới chưa từng thấy (các đặc trưng đã đánh phiên bản). Thuật toán và siêu tham số đã được định trước dựa trên các thiết lập từ giai đoạn thực nghiệm trước đó. Mô hình được huấn luyện lại và tinh chỉnh. (21) Tự động đánh giá mô hình và điều chỉnh siêu tham số theo vòng lặp, nếu cần. Khi các chỉ số hiệu năng cho thấy kết quả tốt, quá trình huấn luyện lặp tự động sẽ dừng lại. Tác vụ huấn luyện mô hình tự động và tác vụ kiểm định mô hình tự động có thể được lặp lại cho tới khi đạt được kết quả tốt. (22) Mô hình đã huấn luyện sau đó được xuất ra và (23) được đẩy lên model registry (C6), nơi nó được lưu trữ, ví dụ dưới dạng mã nguồn hoặc được đóng gói container cùng với các tệp cấu hình và môi trường liên quan.

Đối với mọi lượt lặp của công việc huấn luyện, kho siêu dữ liệu ML (C7) ghi lại siêu dữ liệu như các tham số dùng để huấn luyện mô hình và các chỉ số hiệu năng thu được. Điều này cũng bao gồm việc theo dõi và ghi log ID của công việc huấn luyện, ngày giờ huấn luyện, thời lượng và nguồn gốc của các artifact. Ngoài ra, siêu dữ liệu riêng của mô hình được gọi là “model lineage” — kết hợp nguồn gốc của dữ liệu và mã nguồn — được theo dõi cho mỗi mô hình mới được đăng ký. Điều này bao gồm nguồn và phiên bản của dữ liệu đặc trưng cũng như mã huấn luyện mô hình đã dùng để huấn luyện mô hình đó. Đồng thời, phiên bản và trạng thái của mô hình (ví dụ staging hay sẵn sàng cho production) cũng được ghi lại.

Một khi trạng thái của một mô hình có hiệu năng tốt được chuyển từ staging sang production, nó sẽ tự động được bàn giao cho kỹ sư DevOps hoặc kỹ sư ML để triển khai mô

hình. Từ đó, (24) thành phần CI/CD (C1) kích hoạt pipeline triển khai liên tục. Mô hình ML sẵn sàng cho production và mã phục vụ mô hình được kéo về (vốn được chuẩn bị ban đầu bởi kỹ sư phần mềm (R5)). Pipeline triển khai liên tục thực hiện bước build và test đối với mô hình ML và mã phục vụ, rồi triển khai mô hình để phục vụ trong production. (25) Thành phần phục vụ mô hình (C8) đưa ra dự đoán trên dữ liệu mới, chưa từng thấy, đến từ hệ thống feature store (C4). Thành phần này có thể được kỹ sư phần mềm (R5) thiết kế dưới dạng suy luận trực tuyến cho dự đoán thời gian thực, hoặc suy luận theo lô cho dự đoán trên khối lượng lớn dữ liệu đầu vào. Đối với dự đoán thời gian thực, các đặc trưng phải đến từ cơ sở dữ liệu online (độ trễ thấp), trong khi đối với dự đoán theo lô, các đặc trưng có thể được phục vụ từ cơ sở dữ liệu offline (độ trễ bình thường). Các ứng dụng phục vụ mô hình thường được cấu hình bên trong một container và các yêu cầu dự đoán được xử lý qua REST API. Như một yêu cầu nền tảng, kỹ sư ML (R7) quản lý hạ tầng tính toán phục vụ mô hình. (26) Thành phần giám sát (C9) quan sát liên tục hiệu năng phục vụ mô hình và hạ tầng theo thời gian thực. Khi một ngưỡng nhất định bị chạm tới, chẳng hạn phát hiện độ chính xác dự đoán thấp, thông tin sẽ được chuyển tiếp qua vòng phản hồi. (27) Vòng phản hồi được kết nối với thành phần giám sát (C9) và bảo đảm phản hồi nhanh, trực tiếp, cho phép các dự đoán bền vững và cải thiện hơn. Nó cho phép huấn luyện liên tục, huấn luyện lại và cải tiến. Với sự hỗ trợ của vòng phản hồi, thông tin được chuyển từ thành phần giám sát mô hình tới nhiều điểm tiếp nhận ở thượng nguồn, chẳng hạn giai đoạn thực nghiệm, vùng kỹ nghệ dữ liệu và bộ lập lịch (trigger). Phản hồi tới giai đoạn thực nghiệm được nhà khoa học dữ liệu tiếp nhận để cải tiến mô hình thêm. Phản hồi tới vùng kỹ nghệ dữ liệu cho phép điều chỉnh các đặc trưng được chuẩn bị cho hệ thống feature store. Ngoài ra, việc phát hiện trôi khái niệm (concept drift) như một cơ chế phản hồi có thể cho phép (28) huấn luyện liên tục. Chẳng hạn, một khi thành phần giám sát mô hình (C9) phát hiện độ trôi trong dữ liệu [3], thông tin sẽ được chuyển tới bộ lập lịch, và bộ lập lịch sau đó kích hoạt pipeline luồng công việc ML tự động để huấn luyện lại (huấn luyện liên tục). Sự thay đổi về mức độ phù hợp của mô hình đã triển khai có thể được phát hiện bằng cách so sánh phân phối để nhận diện độ trôi. Việc huấn luyện lại không chỉ được kích hoạt tự động khi một ngưỡng thống kê bị chạm tới; nó cũng có thể được kích hoạt khi có dữ liệu đặc trưng mới, hoặc được lập lịch theo chu kỳ.

6 Khái niệm hóa

Với những phát hiện đang có, chúng tôi khái niệm hóa tài liệu và các cuộc phỏng vấn. Có thể thấy rõ rằng thuật ngữ MLOps nằm ở phần giao nhau giữa học máy, kỹ nghệ phần mềm, DevOps và kỹ nghệ dữ liệu (xem Hình 5 trong Phụ lục). Chúng tôi định nghĩa MLOps như sau:

MLOps (Machine Learning Operations) là một hệ hình (paradigm), bao gồm những khía cạnh như các thực hành tốt nhất, các tập hợp khái niệm, cũng như một văn hóa phát triển, khi nói tới việc khái niệm hóa, triển khai, giám sát, đưa vào vận hành và mở rộng quy mô các sản phẩm học máy theo hướng đầu-cuối. Trên hết, đó là một thực hành kỹ nghệ khai thác ba lĩnh vực đóng góp: học máy, kỹ nghệ phần mềm (đặc biệt là DevOps) và kỹ nghệ dữ liệu. MLOps hướng tới việc đưa các hệ thống học máy vào sản xuất bằng cách bắc cầu qua khoảng cách giữa phát triển (Dev) và vận hành (Ops). Về bản chất, MLOps nhằm tạo thuận lợi cho việc tạo ra các sản phẩm học máy bằng cách khai thác những nguyên tắc sau: tự động hóa CI/CD; điều phối luồng công việc; khả năng tái lập; quản lý phiên bản dữ liệu, mô hình và mã nguồn; cộng tác; huấn luyện và đánh giá ML liên tục; theo dõi và ghi log siêu dữ liệu ML; giám sát liên tục; và các vòng phản hồi.

7 Những thách thức còn bỏ ngỏ

Sau khi tiến hành tổng quan tài liệu, khảo sát công cụ và nghiên cứu phỏng vấn, nhiều thách thức đối với việc áp dụng MLOps đã được nhận diện. Những thách thức còn bỏ ngỏ này được sắp xếp thành các nhóm: thách thức về tổ chức, thách thức về hệ thống ML và thách thức về vận hành.

Thách thức về tổ chức. Tư duy và văn hóa của thực hành khoa học dữ liệu là một thách thức điển hình trong bối cảnh tổ chức [2]. Như những hiểu biết từ tài liệu và phỏng vấn của chúng tôi cho thấy, để phát triển và vận hành thành công các sản phẩm ML, cần có một sự dịch chuyển văn hóa, rời khỏi học máy hướng-mô-hình để tiến tới một ngành hướng-sản-phẩm [γ]. Xu hướng gần đây về AI lấy dữ liệu làm trung tâm (data-centric AI) cũng đề cập tới khía cạnh này, bằng cách đặt nhiều trọng tâm hơn vào các khía cạnh liên quan tới dữ liệu diễn ra trước khi xây dựng mô hình ML. Đặc biệt, những vai trò gắn với các hoạt động này cần có góc nhìn hướng-sản-phẩm khi thiết kế sản phẩm ML [γ]. MLOps đòi hỏi một số lượng lớn kỹ năng và các vai trò riêng lẻ (β). Như các nguồn mà chúng tôi nhận diện đã chỉ ra, đang có sự thiếu hụt chuyên gia trình độ cao cho những vai trò này — đặc biệt là với kiến trúc sư, kỹ sư dữ liệu, kỹ sư ML và kỹ sư DevOps [29,41,44] [α , ϵ]. Điều này liên quan tới việc đào tạo cần thiết cho các chuyên gia tương lai — bởi MLOps thường không nằm trong chương trình đào tạo khoa học dữ liệu [7] [γ]. Posoldova (2020) [35] nhấn mạnh thêm khía cạnh này khi nhận xét rằng sinh viên không chỉ nên học về việc tạo ra mô hình, mà còn phải học về các công nghệ và thành phần cần thiết để xây dựng những sản phẩm ML có khả năng hoạt động.

Riêng các nhà khoa học dữ liệu thì không thể đạt được các mục tiêu của MLOps. Cần có một đội ngũ đa ngành [14], do đó MLOps cần phải là một quá trình nhóm [α]. Điều này thường bị cản trở bởi các đội làm việc trong những ốc đảo riêng thay vì trong những thiết lập hợp tác [α]. Ngoài ra, mức độ tri thức khác nhau và thuật ngữ chuyên ngành riêng biệt khiến việc giao tiếp trở nên khó khăn. Để đặt nền móng cho những thiết lập hiệu quả hơn, cần thuyết phục được những người ra quyết định tương ứng rằng việc nâng cao độ trưởng thành MLOps và một tư duy hướng-sản-phẩm sẽ mang lại những cải thiện kinh doanh rõ ràng [γ].

Thách thức về hệ thống ML. Một thách thức lớn liên quan tới các hệ thống MLOps là thiết kế cho nhu cầu biến động, đặc biệt trong mối liên hệ với quá trình huấn luyện ML [7]. Điều này bắt nguồn từ dữ liệu có khối lượng lớn và biến thiên [10], khiến việc ước lượng chính xác các tài nguyên hạ tầng cần thiết (CPU, RAM và GPU) trở nên khó khăn, và đòi hỏi mức độ linh hoạt cao về khả năng mở rộng của hạ tầng [7,26] [δ].

Thách thức về vận hành. Trong môi trường sản xuất, việc vận hành ML một cách thủ công là rất khó khăn do có nhiều tầng thành phần phần mềm và phần cứng khác nhau cùng sự tương tác giữa chúng. Do đó, cần có tự động hóa bền vững [7,17]. Ngoài ra, dòng dữ liệu mới liên tục đổ về buộc phải có năng lực huấn luyện lại. Đây là một tác vụ lặp đi lặp lại, và một lần nữa, đòi hỏi mức độ tự động hóa cao [18] [θ]. Những tác vụ lặp lại này tạo ra một số lượng lớn artifact, đòi hỏi sự quản trị chặt chẽ [24,29,40] cũng như việc quản lý phiên bản dữ liệu, mô hình và mã nguồn để bảo đảm tính bền vững và khả năng tái lập [11,27,29]. Cuối cùng, việc xử lý một yêu cầu hỗ trợ tiềm tàng (ví dụ tìm ra nguyên nhân gốc rễ) là khó khăn, bởi có rất nhiều bên và thành phần tham gia. Sự cố có thể là sự kết hợp của cả hạ tầng ML lẫn phần mềm [26].

8 Kết luận

Cùng với sự gia tăng về mức độ sẵn có của dữ liệu và năng lực phân tích, kết hợp với áp lực đổi mới liên tục, ngày càng có nhiều sản phẩm học máy được phát triển hơn bao giờ hết. Tuy nhiên, chỉ một số ít trong các bản chứng minh khái niệm này tiến được tới giai đoạn triển khai và vận hành sản xuất. Hơn nữa, không gian học thuật đã tập trung rất mạnh vào việc xây dựng và đánh giá chuẩn mô hình học máy, nhưng lại quá ít vào việc vận hành những hệ thống học máy phức tạp trong các kịch bản thực tế. Trong thực tế, chúng tôi quan sát thấy các nhà khoa học dữ liệu vẫn phải quản lý các luồng công việc ML một cách thủ công ở mức độ rất lớn. Hệ hình Machine Learning Operations (MLOps) ra đời để giải quyết những thách thức này. Trong công trình này, chúng tôi soi sáng thêm về MLOps. Bằng cách tiến hành một nghiên cứu hỗn hợp phương pháp, phân tích tài liệu và công cụ hiện có, cũng như phỏng vấn tám chuyên gia trong ngành, chúng tôi làm rõ bốn khía cạnh chính của MLOps: các nguyên tắc, các thành phần, các vai trò và kiến trúc. Từ những khía cạnh này, chúng tôi suy ra một định nghĩa mang tính tổng thể. Các kết quả này hỗ trợ một cách hiểu chung về thuật ngữ MLOps và các khái niệm liên quan, và hy vọng sẽ giúp các nhà nghiên cứu cũng như giới chuyên môn thiết lập những dự án ML thành công trong tương lai.

PHỤ LỤC


Bảng 1. Danh sách các công nghệ được đánh giá

Nhóm	Tên công nghệ	Mô tả	Nguồn
Ví dụ mã nguồn mở	TensorFlow Extended (TFX)	TensorFlow Extended (TFX) là một framework cấu hình cung cấp các thư viện cho từng tác vụ của một pipeline ML đầu-cuối. Ví dụ gồm kiểm định dữ liệu, kiểm tra phân phối dữ liệu, huấn luyện mô hình và phục vụ mô hình.	[7,10,26,46] [δ, θ]
	Airflow	Airflow là công cụ điều phối tác vụ và luồng công việc, cũng có thể dùng để điều phối luồng công việc ML. Nó cũng được dùng để điều phối các công việc kỹ nghệ dữ liệu. Các tác vụ được thực thi theo đồ thị có hướng không chu trình (DAG).	[26,40,41] [α, β, ζ, η]
	Kubeflow	Kubeflow là một nền tảng ML đầu-cuối dựa trên Kubernetes. Mỗi thành phần Kubeflow được đóng gói trong một container và được Kubernetes điều phối. Đồng thời, mỗi tác vụ của một pipeline luồng công việc ML được xử lý bằng một container.	[26,35,40,41,46] [α, β, γ, δ, ζ, η, θ]
	MLflow	MLflow là một nền tảng ML cho phép quản lý vòng đời ML theo hướng đầu-cuối. Nó cung cấp chức năng theo dõi thí nghiệm nâng cao, một model registry và một thành phần phục vụ mô hình.	[11,32,35] [α, γ, ε, ζ, η, θ]
Ví dụ thương mại	Databricks managed MLflow	Nền tảng Databricks cung cấp các dịch vụ được quản lý dựa trên hạ tầng của những nhà cung cấp đám mây khác, ví dụ MLflow được quản lý (managed MLflow).	[26,32,35,40] [α, ζ]
	Amazon CodePipeline	Amazon CodePipeline là công cụ tự động hóa CI/CD nhằm hỗ trợ các bước build, test và delivery. Nó cũng cho phép lập lịch và quản lý các giai đoạn khác nhau của một pipeline ML.	[18] [γ]
	Amazon SageMaker	Với SageMaker, Amazon AWS cung cấp một nền tảng ML đầu-cuối. Nó cung cấp sẵn một feature store, khả năng điều phối bằng SageMaker Pipelines, và phục vụ mô hình qua SageMaker endpoints.	[7,11,18,24,35] [α, β, γ, ζ, θ]
	Azure DevOps Pipelines	Azure DevOps Pipelines là công cụ tự động hóa CI/CD nhằm hỗ trợ các bước build, test và delivery. Nó cũng cho phép lập lịch và quản lý các giai đoạn khác nhau của một pipeline ML.	[18,42] [γ, ε]
	Azure ML	Microsoft Azure, kết hợp giữa Azure DevOps Pipelines và Azure ML, cung cấp một nền tảng ML đầu-cuối.	[6,24,25,35,42] [α, γ, ε, ζ, η, θ]
	GCP – Vertex AI	GCP, cùng với Vertex AI, cung cấp một nền tảng đầu-cuối được quản lý hoàn toàn. Ngoài ra, họ còn cung cấp cụm Kubernetes được quản lý với Kubeflow dưới dạng dịch vụ.	[25,35,40,41] [α, γ, δ, ζ, θ]
	IBM Cloud Pak for Data (IBM Watson Studio)	IBM Cloud Pak for Data kết hợp một danh sách phần mềm trong một gói, cung cấp các năng lực về dữ liệu và ML.	[41] [γ]

Bảng 2. Danh sách các đối tác phỏng vấn

Bí danh người được phỏng vấn	Chức danh	Số năm kinh nghiệm với DevOps	Số năm kinh nghiệm với ML	Ngành	Quy mô công ty (số nhân viên)
Alpha (α)	Senior Data Platform Engineer	3	4	Hàng thể thao / Bán lẻ	60.000
Beta (β)	Solution Architect / Chuyên gia về ML và AI	6	10	Dịch vụ CNTT / Nhà cung cấp đám mây / Điện toán đám mây	25.000
Gamma (γ)	AI Architect / Consultant	5	7	Nhà cung cấp đám mây	350.000
Delta (δ)	Technical Marketing & Manager về ML / AI	10	5	Nhà cung cấp đám mây	139.995
Epsilon (ε)	Technical Architect – Data & AI	1	2	Nhà cung cấp đám mây	160.000
Zeta (ζ)	ML Engineering Consultant	5	6	Công ty tư vấn	569.000

Bí danh người được phỏng vấn	Chức danh	Số năm kinh nghiệm với DevOps	Số năm kinh nghiệm với ML	Ngành	Quy mô công ty (số nhân viên)
Eta (η)	Engineering Manager về AI / Senior Deep Learning Engineer	10	10	Tập đoàn đa ngành	400.000
Theta (θ)	ML Platform Product Lead	8	10	Phát trực tuyến nhạc / âm thanh	6.500



Hình 5. Phân giao nhau giữa các lĩnh vực của hệ hình MLOps

TÀI LIỆU THAM KHẢO

Danh mục tài liệu tham khảo được giữ nguyên theo bản gốc, không dịch, nhằm bảo đảm khả năng truy vết nguồn.

- [1] Muratahan Aykol, Patrick Herring, and Abraham Anapolsky. 2020. Machine learning for continuous innovation in battery technologies. *Nat. Rev. Mater.* 5, 10 (2020), 725–727.
- [2] Lucas Baier, Fabian Jöhren, and Stefan Seebacher. 2020. Challenges in the deployment and operation of machine learning in practice. 27th Eur. Conf. Inf. Syst. - Inf. Syst. a Shar. Soc. ECIS 2019 (2020), 0–15.
- [3] Lucas Baier, Niklas Kühl, and Gerhard Satzger. 2019. How to Cope with Change? Preserving Validity of Predictive Services over Time. In *Hawaii International Conference on System Sciences (HICSS-52)*, Grand Wailea, Maui, Hawaii, USA.
- [4] Amitabha Banerjee, Chien Chia Chen, Chien Chun Hung, Xiaobo Huang, Yifan Wang, and Razvan Chevesaran. 2020. Challenges and experiences with MLOps for performance diagnostics in hybrid-cloud enterprise software deployments. *OpML 2020 - 2020 USENIX Conf. Oper. Mach. Learn.* (2020), 7–9.
- [5] Kent Beck, Mike Beedle, Arie van Bennekum, Alistair Cockburn, Ward Cunningham, Martin Fowler, James Grenning, Jim Highsmith, Andrew Hunt, Ron Jeffries, Jon Kern, Brian Marick, Robert C. Martin, Steve Mellor, Ken Schwaber, Jeff Sutherland, and Dave Thomas. 2001. *Manifesto for Agile Software Development*. (2001).
- [6] Benjamin Benni, Blay Fornarino Mireille, Mosser Sebastien, Precisio Frederic, and Jungbluth Gunther. 2019. When DevOps meets meta- learning: A portfolio to rule them all. *Proc. - 2019 ACM/IEEE 22nd Int. Conf. Model Driven Eng. Lang. Syst. Companion, Model. 2019* (2019), 605–612. DOI:<https://doi.org/10.1109/MODELS-C.2019.00092>
- [7] Lucas Cardoso Silva, Fernando Rezende Zagatti, Bruno Silva Sette, Lucas Nildaimon Dos Santos Silva, Daniel Lucredio, Diego Furtado Silva, and Helena De Medeiros Caseli. 2020. Benchmarking Machine Learning Solutions in Production. *Proc. - 19th IEEE Int. Conf. Mach. Learn. Appl. ICMLA 2020* (2020), 626–633. DOI:<https://doi.org/10.1109/ICMLA51294.2020.00104>
- [8] Juliet M. Corbin and Anselm Strauss. 1990. Grounded theory research: Procedures, canons, and evaluative criteria. *Qual. Sociol.* 13, 1 (1990), 3–21. DOI:<https://doi.org/10.1007/BF00988593>
- [9] Patrick Debois. 2009. Patrick Debois - devopsdays Ghent. Retrieved March 25, 2021 from <https://devopsdays.org/events/2019-ghent/speakers/patrick-debois/>
- [10] Behrouz Derakhshan, Alireza Rezaei Mahdiraji, Tilmann Rabl, and Volker Markl. 2019. Continuous deployment of machine learning pipelines. *Adv. Database Technol. - EDBT 2019-March*, (2019), 397–408. DOI:<https://doi.org/10.5441/002/edbt.2019.35>
- [11] Grigori Fursin. 2021. Collective knowledge: organizing research projects as a database of reusable components and portable workflows with common interfaces. *Philos. Trans. A. Math. Phys. Eng. Sci.* 379, 2197 (2021), 20200211. DOI:<https://doi.org/10.1098/rsta.2020.0211>
- [12] Barney Glaser and Anselm Strauss. 1967. The discovery of grounded theory: strategies for qualitative research.
- [13] Mahendra Kumar Gourisaria, Rakshit Agrawal, G M Harshvardhan, Manjusha Pandey, and Siddharth Swarup Rautaray. 2021. Application of Machine Learning in Industry 4.0. In *Machine Learning: Theoretical Foundations and Practical Applications*. Springer, 57–87.
- [14] Akshita Goyal. 2020. MLOps - Machine Learning Operations. *Int. J. Inf. Technol. Insights Transform.* (2020). Retrieved April 15, 2021 from <http://technology.eurekajournals.com/index.php/IJITIT/article/view/655/769>
- [15] Tuomas Granlund, Aleksi Kopponen, Vlad Stirbu, Lalli Myllyaho, and Tommi Mikkonen. 2021. MLOps Challenges in Multi-Organization Setup: Experiences from Two Real-World Cases. (2021). Retrieved from <http://arxiv.org/abs/2103.08937>
- [16] Willem Jan van den Heuvel and Damian A. Tamburri. 2020. *Model-driven ml-ops for intelligent enterprise applications: vision, approaches and challenges*. Springer International Publishing. DOI:https://doi.org/10.1007/978-3-030-52306-0_11
- [17] Ioannis Karamitsos, Saeed Albarhami, and Charalampos Apostolopoulos. 2020. Applying devops practices of continuous automation for machine learning. *Inf.* 11, 7 (2020), 1–15. DOI:<https://doi.org/10.3390/info11070363>
- [18] Bojan Karlaš, Matteo Interlandi, Cedric Renggli, Wentao Wu, Ce Zhang, Deepak Mukunthu Iyappan Babu, Jordan Edwards, Chris Lauren, Andy Xu, and Markus Weimer. 2020. Building Continuous Integration Services for Machine Learning. *Proc. ACM SIGKDD Int. Conf. Knowl. Discov. Data Min.* (2020), 2407–2415. DOI:<https://doi.org/10.1145/3394486.3403290>
- [19] Rupesh Raj Karn, Prabhakar Kudva, and Ibrahim Abe M. Elfadel. 2019. Dynamic autoselection and autotuning of machine learning models for cloud network analytics. *IEEE Trans. Parallel Distrib. Syst.* 30, 5 (2019), 1052–1064. DOI:<https://doi.org/10.1109/TPDS.2018.2876844>
- [20] Barbara Kitchenham, O. Pearl Brereton, David Budgen, Mark Turner, John Bailey, and Stephen Linkman. 2009. Systematic literature reviews in software engineering - A systematic literature review. *Inf. Softw. Technol.* 51, 1 (2009), 7–15. DOI:<https://doi.org/10.1016/j.infsof.2008.09.009>

- [21] Rafal Kocielnik, Saleema Amershi, and Paul N Bennett. 2019. Will you accept an imperfect ai? exploring designs for adjusting end-user expectations of ai systems. In *Proceedings of the 2019 CHI Conference on Human Factors in Computing Systems*, 1–14.
- [22] Ana De Las Heras, Amalia Luque-Sendra, and Francisco Zamora-Polo. 2020. Machine learning technologies for sustainability in smart cities in the post-covid era. *Sustainability* 12, 22 (2020), 9320.
- [23] Leonardo Leite, Carla Rocha, Fabio Kon, Dejan Milojicic, and Paulo Meirelles. 2019. A survey of DevOps concepts and challenges. *ACM Comput. Surv.* 52, 6 (2019). DOI:<https://doi.org/10.1145/3359981>
- [24] Yan Liu, Zhijing Ling, Boyu Huo, Boqian Wang, Tianen Chen, and Esma Mouine. 2020. Building A Platform for Machine Learning Operations from Open Source Frameworks. *IFAC-PapersOnLine* 53, 5 (2020), 704–709. DOI:<https://doi.org/10.1016/j.ifacol.2021.04.161>
- [25] Alvaro Lopez Garcia, Viet Tran, Andy S. Alic, Miguel Caballer, Isabel Campos Plasencia, Alessandro Costantini, Stefan Dlugolinsky, Doina Cristina Duma, Giacinto Donvito, Jorge Gomes, Ignacio Heredia Cacha, Jesus Marco De Lucas, Keiichi Ito, Valentin Y. Kozlov, Giang Nguyen, Pablo Orviz Fernandez, Zdenek Sustr, Pawel Wolniewicz, Marica Antonacci, Wolfgang Zu Castell, Mario David, Marcus Hardt, Lara Lloret Iglesias, Germen Molto, and Marcin Plociennik. 2020. A cloud-based framework for machine learning workloads and applications. *IEEE Access* 8, (2020), 18681–18692. DOI:<https://doi.org/10.1109/ACCESS.2020.2964386>
- [26] Lwakatare. 2020. From a Data Science Driven Process to a Continuous Delivery Process for Machine Learning Systems. *Lect. Notes Comput. Sci. (including Subser. Lect. Notes Artif. Intell. Lect. Notes Bioinformatics)* 12562 LNCS, (2020), 185–201. DOI:https://doi.org/10.1007/978-3-030-64148-1_12
- [27] Lwakatare. 2020. DevOps for AI - Challenges in Development of AI- enabled Applications. (2020). DOI:<https://doi.org/10.23919/SoftCOM50211.2020.9238323>
- [28] Ruth W. Macarthy and Julian M. Bass. 2020. An Empirical Taxonomy of DevOps in Practice. In *2020 46th Euromicro Conference on Software Engineering and Advanced Applications (SEAA)*, IEEE, 221–228. DOI:<https://doi.org/10.1109/SEAA51224.2020.00046>
- [29] Sasu Mäkinen, Henrik Skogström, Eero Laaksonen, and Tommi Mikkonen. 2021. Who Needs MLOps: What Data Scientists Seek to Accomplish and How Can MLOps Help? *MI* (2021). Retrieved from <http://arxiv.org/abs/2103.08942>
- [30] Rob van der Meulen and Thomas McCall. 2018. Gartner Says Nearly Half of CIOs Are Planning to Deploy Artificial Intelligence. Retrieved December 4, 2021 from <https://www.gartner.com/en/newsroom/press-releases/2018-02-13-gartner-says-nearly-half-of-cios-are-planning-to-deploy-artificial-intelligence>
- [31] Steve Mezak. 2018. The Origins of DevOps: What's in a Name? - DevOps.com. Retrieved March 25, 2021 from <https://devops.com/the-origins-of-devops-whats-in-a-name/>
- [32] Antonio Molner Domenech and Alberto Guillén. 2020. ML-experiment: A Python framework for reproducible data science. *J. Phys. Conf. Ser.* 1603, 1 (2020). DOI:<https://doi.org/10.1088/1742-6596/1603/1/012025>
- [33] Michael D. Myers and Michael Newman. 2007. The qualitative interview in IS research: Examining the craft. *Inf. Organ.* 17, 1 (2007), 2–26. DOI:<https://doi.org/10.1016/j.infoandorg.2006.11.001>
- [34] Pulasthi Perera, Roshali Silva, and Indika Perera. 2017. Improve software quality through practicing DevOps. In *2017 Seventeenth International Conference on Advances in ICT for Emerging Regions (ICTer)*, 1–6.
- [35] Alexandra Posoldova. 2020. Machine Learning Pipelines: From Research to Production. *IEEE POTENTIALS* (2020).
- [36] Cedric Renggli, Luka Rimanic, Nezihe Merve Gürel, Bojan Karlaš, Wentao Wu, and Ce Zhang. 2021. A Data Quality-Driven View of MLOps. 1 (2021), 1–12. Retrieved from <http://arxiv.org/abs/2102.07750>
- [37] Winston W. Royce. 1970. Managing the Development of Large Software Systems. (1970).
- [38] Martin Rütz. 2019. DEVOPS: A SYSTEMATIC LITERATURE REVIEW. *Inf. Softw. Technol.* (2019).
- [39] Ulrike Schultze and Michel Avital. 2011. Designing interviews to generate rich data for information systems research. *Inf. Organ.* 21, 1 (2011), 1–16. DOI:<https://doi.org/10.1016/j.infoandorg.2010.11.001>
- [40] Ola Spjuth, Jens Frid, and Andreas Hellander. 2021. The machine learning life cycle and the cloud: implications for drug discovery. *Expert Opin. Drug Discov.* 00, 00 (2021), 1–9. DOI:<https://doi.org/10.1080/17460441.2021.1932812> MLOps
- [41] Damian A. Tamburri. 2020. Sustainable MLOps: Trends and Challenges. *Proc. - 2020 22nd Int. Symp. Symb. Numer. Algorithms Sci. Comput. SYNASC 2020* (2020), 17–23. DOI:<https://doi.org/10.1109/SYNASC51798.2020.00015>
- [42] Chandrasekar Vuppapapati, Anitha Ilapakurti, Karthik Chillara, Sharat Kedari, and Vanaja Mamidi. 2020. Automating Tiny ML Intelligent Sensors DevOPS Using Microsoft Azure. *Proc. - 2020 IEEE Int. Conf. Big Data, Big Data 2020* (2020), 2375–2384. DOI:<https://doi.org/10.1109/BigData50022.2020.9377755>
- [43] Jane Webster and Richard Watson. 2002. Analyzing the Past to Prepare for the Future: Writing a Literature Review. *MIS Q.* 26, 2 (2002), xiii–xxiii. DOI:<https://doi.org/10.1.1.104.6570>
- [44] Chaoyu Wu, E. Haihong, and Meina Song. 2020. An Automatic Artificial Intelligence Training Platform Based on Kubernetes. *ACM Int. Conf. Proceeding Ser.* (2020), 58–62. DOI:<https://doi.org/10.1145/3378904.3378921>
- [45] Geum Seong Yoon, Jungsu Han, Seunghyung Lee, and Jong Won Kim. 2020. DevOps Portal Design for SmartX AI Cluster Employing Cloud- Native Machine Learning Workflows. Springer International Publishing. DOI:https://doi.org/10.1007/978-3-030-39746-3_54