

Giáo trình Xử lý ngôn ngữ tự nhiên (NLP)

Giới thiệu

Giáo trình này cung cấp một cái nhìn tổng quan toàn diện về Xử lý ngôn ngữ tự nhiên (NLP), một lĩnh vực con của Trí tuệ nhân tạo (AI) tập trung vào việc cho phép máy tính hiểu, diễn giải và tạo ra ngôn ngữ của con người. NLP đóng vai trò quan trọng trong nhiều ứng dụng hiện đại như dịch máy, phân tích cảm xúc, chatbot, và tìm kiếm thông tin.

Giáo trình sẽ đi sâu vào các giai đoạn xử lý ngôn ngữ chính, bao gồm xử lý từ vựng (Lexical Processing), xử lý cú pháp (Syntactic Processing), và xử lý ngữ nghĩa (Semantic Processing). Ngoài ra, giáo trình còn bao gồm một dự án thực hành phân loại ticket để học viên có thể áp dụng kiến thức đã học vào thực tế.

Mục lục

1. NLP - Lexical Processing
2. NLP - Syntactic Processing
3. NLP Assignment - Syntactic Processing
4. NLP - Semantic Processing I
5. NLP - Semantic Processing II
6. Ticket classification Project

1. NLP - Lexical Processing

1.1. Giới thiệu về Lexical Processing

Lexical Processing, hay còn gọi là phân tích từ vựng hoặc phân tích hình thái, là giai đoạn đầu tiên và cơ bản nhất trong quá trình xử lý ngôn ngữ tự nhiên (NLP). Giai đoạn này tập trung vào việc nhận diện và xử lý các từ (hoặc lexeme) trong một văn bản. Mục tiêu chính là chuyển đổi văn bản thô thành các đơn vị có ý nghĩa nhỏ hơn, tạo nền tảng cho các phân tích sâu hơn ở các giai đoạn sau [1, 2].

Quá trình này bao gồm việc chia nhỏ văn bản thành các token riêng lẻ, loại bỏ các yếu tố không cần thiết và chuẩn hóa các từ để chúng có thể được máy tính hiểu và xử lý một cách hiệu quả. Lexical Processing đóng vai trò quan trọng trong việc chuẩn bị dữ liệu văn bản, giúp các thuật toán NLP hoạt động chính xác và hiệu quả hơn.

1.2. Các kỹ thuật chính trong Lexical Processing

1.2.1. Tokenization (Tách từ)

Tokenization là quá trình chia một chuỗi văn bản thành các đơn vị nhỏ hơn gọi là token. Các token này thường là các từ, nhưng cũng có thể là các ký tự, cụm từ, hoặc các đơn vị có ý nghĩa khác tùy thuộc vào mục tiêu của ứng dụng. Ví dụ, câu "Tôi yêu Việt Nam." có thể được tách thành các token: "Tôi", "yêu", "Việt", "Nam", "." [3].

Có nhiều phương pháp tokenization khác nhau, từ đơn giản như tách theo khoảng trắng đến phức tạp hơn như sử dụng các quy tắc ngữ pháp hoặc mô hình học máy để xử lý các trường hợp đặc biệt như từ ghép, dấu câu, hoặc các ngôn ngữ không có khoảng trắng rõ ràng (ví dụ: tiếng Trung, tiếng Nhật).

1.2.2. Stop Word Removal (Loại bỏ từ dừng)

Từ dừng (stop words) là những từ phổ biến trong một ngôn ngữ (ví dụ: "là", "và", "của", "một" trong tiếng Việt; "the", "a", "is" trong tiếng Anh) mà thường không mang nhiều ý nghĩa quan trọng trong việc phân tích ngữ nghĩa của văn bản. Việc loại bỏ các từ dừng giúp giảm kích thước dữ liệu, tăng tốc độ xử lý và cải thiện hiệu suất của các mô hình NLP bằng cách tập trung vào các từ khóa quan trọng hơn [4].

Tuy nhiên, việc loại bỏ từ dừng cần được cân nhắc kỹ lưỡng, vì trong một số trường hợp, từ dừng có thể mang ý nghĩa quan trọng (ví dụ: trong phân tích cảm xúc, từ "không" có thể thay đổi hoàn toàn ý nghĩa của câu).

1.2.3. Stemming (Cắt bỏ hậu tố)

Stemming là quá trình rút gọn các từ về dạng gốc của chúng bằng cách cắt bỏ các hậu tố hoặc tiền tố. Mục tiêu là đưa các từ có cùng gốc về một dạng duy nhất, ngay cả khi chúng có các biến thể hình thái khác nhau. Ví dụ, các từ "running", "runs", "ran" có thể được rút gọn về "run" [5].

Stemming là một kỹ thuật đơn giản và nhanh chóng, nhưng nó có thể không tạo ra các từ có nghĩa thực sự. Ví dụ, "universal" có thể bị cắt thành "univers", không phải là một từ tiếng Anh hợp lệ. Các thuật toán stemming phổ biến bao gồm Porter Stemmer và Snowball Stemmer.

1.2.4. Lemmatization (Đưa về dạng nguyên thể)

Lemmatization là quá trình phức tạp hơn stemming, nhằm mục đích đưa các từ về dạng nguyên thể (lemma) của chúng, đảm bảo rằng dạng gốc là một từ có nghĩa trong từ điển. Quá trình này thường sử dụng các quy tắc ngữ pháp và từ điển để phân tích hình thái của từ. Ví dụ, các từ "running", "runs", "ran" đều được đưa về "run", và "better" được đưa về "good" [6].

Lemmatization chính xác hơn stemming nhưng cũng tốn kém hơn về mặt tính toán. Nó thường được ưu tiên trong các ứng dụng yêu cầu độ chính xác cao về ngữ nghĩa.

1.2.5. Part-of-Speech Tagging (Gán nhãn từ loại)

Part-of-Speech (POS) Tagging là quá trình gán nhãn từ loại (ví dụ: danh từ, động từ, tính từ, trạng từ) cho mỗi từ trong một câu. Việc gán nhãn từ loại giúp hiểu rõ hơn vai trò ngữ pháp của từng từ trong câu, từ đó hỗ trợ các giai đoạn xử lý tiếp theo như phân tích cú pháp và ngữ nghĩa [7].

Các mô hình POS tagging thường được huấn luyện trên các tập dữ liệu lớn đã được gán nhãn thủ công và sử dụng các thuật toán học máy như Hidden Markov Models (HMM), Conditional Random Fields (CRF), hoặc các mạng nơ-ron sâu.

1.3. Ứng dụng của Lexical Processing

Lexical Processing là nền tảng cho nhiều ứng dụng NLP, bao gồm:

- **Tìm kiếm thông tin:** Chuẩn hóa từ khóa giúp cải thiện độ chính xác của kết quả tìm kiếm.
- **Phân tích cảm xúc:** Loại bỏ từ dừng và chuẩn hóa từ giúp tập trung vào các từ mang ý nghĩa cảm xúc.
- **Dịch máy:** Phân tích từ vựng là bước đầu tiên để hiểu cấu trúc và ý nghĩa của câu trong ngôn ngữ nguồn.
- **Tóm tắt văn bản:** Giúp xác định các từ khóa quan trọng và loại bỏ các từ không cần thiết.
- **Xây dựng từ điển và kho ngữ liệu:** Hỗ trợ việc tạo ra các tài nguyên ngôn ngữ chất lượng cao.

1.4. Thách thức trong Lexical Processing

Mặc dù là giai đoạn cơ bản, Lexical Processing vẫn đối mặt với một số thách thức:

- **Tính mơ hồ của ngôn ngữ:** Một từ có thể có nhiều nghĩa hoặc nhiều từ có thể có cùng một dạng (ví dụ: "bank" có thể là bờ sông hoặc ngân hàng).
- **Ngôn ngữ không có khoảng trắng:** Các ngôn ngữ như tiếng Trung, tiếng Nhật không sử dụng khoảng trắng để phân tách từ, đòi hỏi các thuật toán tokenization phức tạp hơn.
- **Từ mới và tiếng lóng:** Ngôn ngữ luôn phát triển, và các từ mới hoặc tiếng lóng có thể không có trong từ điển, gây khó khăn cho lemmatization và POS tagging.
- **Xử lý ngôn ngữ đa dạng:** Mỗi ngôn ngữ có các quy tắc ngữ pháp và hình thái riêng, đòi hỏi các mô hình và tài nguyên ngôn ngữ cụ thể.

1.5. Kết luận

Lexical Processing là một bước không thể thiếu trong bất kỳ hệ thống NLP nào. Bằng cách chuyển đổi văn bản thô thành các đơn vị có cấu trúc và ý nghĩa, nó tạo ra nền tảng vững chắc cho các phân tích ngôn ngữ phức tạp hơn. Việc hiểu rõ các kỹ thuật và thách thức của Lexical Processing là rất quan trọng đối với bất kỳ ai muốn làm việc trong lĩnh vực NLP.

Tài liệu tham khảo

[1] GeeksforGeeks. (n.d.). *Phases of Natural Language Processing (NLP)*. Retrieved from <https://www.geeksforgeeks.org/machine-learning/phases-of-natural-language-processing-nlp/> [2] Medium. (2023, December 30). *NLP :Basic Lexical Processing for Text Analysis*. Retrieved from <https://medium.com/@nitin.data1997/nlp-understanding-basic-lexical-processing-for-text-analysis-74df448074ad> [3] Coursera. (n.d.). *What is Lexical Analysis?*. Retrieved from <https://www.coursera.org/articles/lexical-analysis> [4] Medium. (2024, July 11). *An Introduction to NLP for Beginners-PART 2:Lexical Processing*. Retrieved from <https://medium.com/@manucet439/an-introduction-to-nlp-for-beginners-part-2-lexical-processing-coding-c5e61898e47f> [5] GeeksforGeeks. (2023, January 24). *Lexical Analysis and Syntax Analysis*. Retrieved from <https://www.geeksforgeeks.org/compiler-design/lexical-analysis-and-syntax-analysis/> [6] Talend. (n.d.). *What is Natural Language Processing (NLP)?*. Retrieved from <https://www.talend.com/resources/what-is-natural-language-processing-nlp/> [7] IBM. (n.d.). *What Is NLP (Natural Language Processing)?*. Retrieved from <https://www.ibm.com/think/topics/natural-language-processing/>

2. NLP - Syntactic Processing

2.1. Giới thiệu về Syntactic Processing

Syntactic Processing, hay còn gọi là phân tích cú pháp (parsing) hoặc phân tích ngữ pháp, là giai đoạn thứ hai trong quy trình xử lý ngôn ngữ tự nhiên (NLP), sau Lexical Processing. Giai đoạn này tập trung vào việc phân tích cấu trúc ngữ pháp của câu, xác định mối quan hệ giữa các từ và cụm từ để hiểu cách chúng kết hợp với nhau tạo thành một câu có cấu trúc hợp lệ [1, 2].

Mục tiêu chính của Syntactic Processing là xây dựng một biểu diễn cấu trúc của câu, thường dưới dạng cây phân tích cú pháp (parse tree), biểu đồ phụ thuộc (dependency graph) hoặc các cấu trúc ngữ pháp khác. Biểu diễn này giúp máy tính hiểu được vai trò ngữ pháp của từng thành phần trong câu, từ đó làm nền tảng cho việc trích xuất ý nghĩa ở giai đoạn ngữ nghĩa.

2.2. Các khái niệm chính trong Syntactic Processing

2.2.1. Ngữ pháp (Grammar)

Ngữ pháp là tập hợp các quy tắc xác định cách các từ và cụm từ được kết hợp để tạo thành các câu hợp lệ trong một ngôn ngữ. Trong NLP, ngữ pháp thường được biểu diễn dưới dạng ngữ pháp ngữ cảnh tự do (Context-Free Grammar - CFG) hoặc ngữ pháp phụ thuộc (Dependency Grammar).

- **Ngữ pháp ngữ cảnh tự do (CFG):** Định nghĩa các quy tắc sản xuất (production rules) để tạo ra các chuỗi từ hợp lệ. Ví dụ: $S \rightarrow NP VP$ (Câu gồm một Cụm danh từ và một Cụm động từ), $NP \rightarrow Det N$ (Cụm danh từ gồm một Định từ và một Danh từ) [3].
- **Ngữ pháp phụ thuộc (Dependency Grammar):** Tập trung vào mối quan hệ phụ thuộc giữa các từ trong câu, trong đó một từ (head) điều khiển một từ khác (dependent) [4].

2.2.2. Phân tích cú pháp (Parsing)


Parsing là quá trình áp dụng các quy tắc ngữ pháp để xây dựng cấu trúc cú pháp cho một câu. Có hai phương pháp parsing chính:

- **Top-down Parsing (Phân tích từ trên xuống):** Bắt đầu từ ký hiệu bắt đầu (ví dụ: S - Sentence) và cố gắng suy ra câu đầu vào bằng cách áp dụng các quy tắc sản xuất. Ví dụ: Recursive Descent Parser, Predictive Parser.
- **Bottom-up Parsing (Phân tích từ dưới lên):** Bắt đầu từ các token đầu vào và cố gắng kết hợp chúng lại để tạo thành ký hiệu bắt đầu. Ví dụ: Shift-Reduce Parser, LR Parser [5].

2.2.3. Cây phân tích cú pháp (Parse Tree)

Cây phân tích cú pháp là một biểu diễn đồ họa của cấu trúc cú pháp của một câu, được tạo ra bởi quá trình parsing. Mỗi nút trong cây đại diện cho một thành phần ngữ pháp (ví dụ: S, NP, VP), và các lá là các từ trong câu. Cây phân tích cú pháp giúp trực quan hóa mối quan hệ phân cấp giữa các thành phần trong câu [6].

Ví dụ: Câu "The cat sat on the mat."



2.2.4. Phân tích phụ thuộc (Dependency Parsing)

Dependency Parsing là một phương pháp phân tích cú pháp tập trung vào việc xác định các mối quan hệ phụ thuộc giữa các từ trong câu. Thay vì xây dựng cây phân tích ngữ cảnh tự do, dependency parsing tạo ra một biểu đồ phụ thuộc, trong đó mỗi mũi tên chỉ ra mối quan hệ giữa một từ (head) và một từ phụ thuộc (dependent) [7].

Ví dụ: Câu "The cat sat on the mat."

- sat là head của cat (nsubj)
- sat là head của on (prep)
- on là head của mat (pobj)

2.3. Các công cụ và thư viện cho Syntactic Processing

- **NLTK (Natural Language Toolkit):** Một thư viện Python phổ biến cung cấp các công cụ cho tokenization, POS tagging, parsing (bao gồm CFG parsing và dependency parsing) [8].
- **spaCy:** Một thư viện NLP hiệu suất cao cho Python, cung cấp các mô hình được huấn luyện sẵn cho POS tagging, dependency parsing, và nhận dạng thực thể có tên (Named Entity Recognition - NER) [9].
- **Stanford CoreNLP:** Một bộ công cụ NLP toàn diện được viết bằng Java, cung cấp nhiều chức năng bao gồm POS tagging, parsing, NER, coreference resolution, v.v. [10].

2.4. Ứng dụng của Syntactic Processing

Syntactic Processing là một thành phần quan trọng trong nhiều ứng dụng NLP:

- **Trích xuất thông tin:** Xác định các mối quan hệ giữa các thực thể trong câu để trích xuất thông tin có cấu trúc.
- **Dịch máy:** Hiểu cấu trúc ngữ pháp của câu nguồn giúp tạo ra bản dịch chính xác hơn trong ngôn ngữ đích.
- **Phân tích cảm xúc:** Phân tích cú pháp có thể giúp xác định chủ thể của cảm xúc và đối tượng mà cảm xúc đó hướng tới.
- **Hệ thống hỏi đáp:** Giúp hệ thống hiểu được cấu trúc của câu hỏi để tìm kiếm câu trả lời phù hợp.
- **Kiểm tra ngữ pháp và chính tả:** Phát hiện các lỗi ngữ pháp dựa trên cấu trúc câu.

2.5. Thách thức trong Syntactic Processing

- **Tính mơ hồ của ngữ pháp:** Một câu có thể có nhiều cấu trúc cú pháp hợp lệ (ambiguity), dẫn đến nhiều cây phân tích cú pháp khác nhau. Ví dụ: "I saw the man with the telescope." (Người đàn ông có kính thiên văn hay tôi dùng kính thiên văn để nhìn?)
- **Ngôn ngữ phức tạp:** Các ngôn ngữ có cấu trúc ngữ pháp phức tạp, nhiều trường hợp ngoại lệ hoặc trật tự từ linh hoạt có thể gây khó khăn cho việc phân tích cú pháp.
- **Dữ liệu không chuẩn:** Văn bản không chuẩn (ví dụ: tin nhắn, bài đăng mạng xã hội) thường chứa lỗi ngữ pháp, từ viết tắt, hoặc cấu trúc câu không đầy đủ, làm giảm hiệu suất của các parser.

2.6. Kết luận

Syntactic Processing là một bước thiết yếu để máy tính có thể hiểu được cấu trúc và mối quan hệ giữa các từ trong câu. Bằng cách chuyển đổi chuỗi từ thành các biểu diễn ngữ pháp có cấu trúc, nó cung cấp thông tin quan trọng cho các giai đoạn xử lý ngữ nghĩa và các ứng dụng NLP phức tạp hơn.

Tài liệu tham khảo

- [1] GeeksforGeeks. (n.d.). *Phases of Natural Language Processing (NLP)*. Retrieved from <https://www.geeksforgeeks.org/machine-learning/phases-of-natural-language-processing-nlp/> [2] Tutorialspoint. (n.d.). *Natural Language Processing - Syntactic Analysis*. Retrieved from https://www.tutorialspoint.com/natural_language_processing/natural_language_processing_syntactic_analysis.htm [3] Analytics Vidhya. (2021, June 11). *Part 11: Step by Step Guide to Master NLP - Syntactic Analysis*. Retrieved from <https://www.analyticsvidhya.com/blog/2021/06/part-11-step-by-step-guide-to-master-nlp-syntactic-analysis/> [4] ScienceDirect Topics. (n.d.). *Syntactic Processing - an overview*. Retrieved from <https://www.sciencedirect.com/topics/computer-science/syntactic-processing> [5] 101 Blockchains. (2024, March 4). *What Is Syntactic Analysis In NLP?*. Retrieved from <https://101blockchains.com/syntactic-analysis-in-nlp/> [6] Medium. (2024, September 21). *An Introduction to NLP for Beginners-PART 3:-Syntactic Processing*. Retrieved from <https://medium.com/@manucet439/an-introduction-to-nlp-for-beginners-part-3-syntactic-processing-coding-d098db078d6c> [7] Spot Intelligence. (2023, October 28). *Syntactic Analysis: A Power Tool In NLP Made Easy*. Retrieved

from <https://spotintelligence.com/2023/10/28/syntactic-analysis-nlp/> [8] NLTK. (n.d.). *Natural Language Toolkit*. Retrieved from <https://www.nltk.org/> [9] spaCy. (n.d.). *Industrial-strength Natural Language Processing*. Retrieved from <https://spacy.io/> [10] Stanford CoreNLP. (n.d.). *Stanford CoreNLP*. Retrieved from <https://stanfordnlp.github.io/CoreNLP/>

3. NLP Assignment - Syntactic Processing

3.1. Mục tiêu

Bài tập này nhằm mục đích giúp học viên củng cố kiến thức về Syntactic Processing trong NLP thông qua việc thực hành phân tích cú pháp và phụ thuộc trên các câu tiếng Việt.

3.2. Yêu cầu

1. **Cài đặt thư viện:** Đảm bảo rằng bạn đã cài đặt các thư viện cần thiết như `underthesea` (cho tiếng Việt) hoặc `spaCy` (nếu muốn thử với tiếng Anh).

```
bash pip install underthesea pip install spacy python -m spacy download en_core_web_sm
```

2. Phân tích cú pháp (Constituency Parsing):

- Chọn 3 câu tiếng Việt bất kỳ (ví dụ: "Hôm nay trời đẹp.", "Cô gái đang đọc sách trong thư viện.", "Anh ấy mua một chiếc xe hơi mới rất đắt tiền.").
- Sử dụng thư viện `underthesea` để thực hiện phân tích cú pháp cho từng câu. Nếu `underthesea` không hỗ trợ constituency parsing trực tiếp, hãy tìm kiếm các thư viện hoặc công cụ khác có thể làm được điều này cho tiếng Việt, hoặc sử dụng `spaCy` với tiếng Anh để minh họa.
- Vẽ cây phân tích cú pháp (parse tree) cho mỗi câu (có thể vẽ thủ công hoặc sử dụng công cụ hỗ trợ nếu có).
- Giải thích cấu trúc của cây phân tích cú pháp và các thành phần ngữ pháp chính (S, NP, VP, PP, v.v.).

3. Phân tích phụ thuộc (Dependency Parsing):

- Sử dụng 3 câu tiếng Việt tương tự hoặc khác với phần trên.
- Sử dụng thư viện `underthesea` hoặc `spaCy` (với tiếng Anh) để thực hiện phân tích phụ thuộc cho từng câu.
- Trực quan hóa biểu đồ phụ thuộc (dependency graph) cho mỗi câu (có thể sử dụng `displacy` của `spaCy` hoặc các công cụ khác).
- Giải thích các mối quan hệ phụ thuộc giữa các từ (ví dụ: `nsubj`, `dobj`, `amod`, `prep`, v.v.).

4. Phân tích lỗi và tính mơ hồ:

- Tìm một câu tiếng Việt có tính mơ hồ về cú pháp (ví dụ: "Tôi thấy con chim trên cây với ống nhòm.").
- Thực hiện phân tích cú pháp hoặc phụ thuộc cho câu này.
- Thảo luận về các cách diễn giải khác nhau của câu và cách mà parser xử lý tính mơ hồ này (hoặc không xử lý được).

3.3. Báo cáo kết quả

Viết một báo cáo ngắn gọn (khoảng 500-800 từ) trình bày các kết quả phân tích của bạn, bao gồm:

- Mã nguồn Python đã sử dụng.
- Cây phân tích cú pháp và biểu đồ phụ thuộc cho các câu đã chọn.

- Giải thích chi tiết về các cấu trúc và mối quan hệ ngữ pháp.
- Phân tích về tính mơ hồ và cách xử lý của parser.
- Nhận xét về ưu và nhược điểm của các công cụ/thư viện đã sử dụng.

3.4. Đánh giá

Bài tập sẽ được đánh giá dựa trên:

- Độ chính xác của phân tích cú pháp và phụ thuộc.
- Khả năng giải thích các khái niệm ngữ pháp.
- Chất lượng của mã nguồn và báo cáo.
- Khả năng nhận diện và phân tích tính mơ hồ của ngôn ngữ.

Chúc các bạn hoàn thành tốt bài tập này!

4. NLP - Semantic Processing I

4.1. Giới thiệu về Semantic Processing

Semantic Processing, hay còn gọi là phân tích ngữ nghĩa, là giai đoạn quan trọng trong Xử lý ngôn ngữ tự nhiên (NLP) nhằm mục đích hiểu ý nghĩa của ngôn ngữ con người. Trong khi Lexical Processing tập trung vào các đơn vị từ vựng và Syntactic Processing phân tích cấu trúc ngữ pháp, Semantic Processing đi sâu hơn để giải mã ý nghĩa thực sự đằng sau các từ, cụm từ và câu [1, 2].

Mục tiêu của phân tích ngữ nghĩa là chuyển đổi các biểu diễn ngôn ngữ tự nhiên thành các biểu diễn có ý nghĩa, cho phép máy tính hiểu được nội dung và ngữ cảnh của văn bản. Điều này bao gồm việc xác định mối quan hệ giữa các từ, giải quyết tính mơ hồ của từ, và hiểu ý nghĩa tổng thể của một đoạn văn bản.

4.2. Các khái niệm chính trong Semantic Processing

4.2.1. Ý nghĩa từ vựng (Lexical Semantics)

Lexical Semantics nghiên cứu ý nghĩa của các từ riêng lẻ. Một thách thức lớn trong lĩnh vực này là tính đa nghĩa của từ (word sense ambiguity), khi một từ có thể có nhiều nghĩa khác nhau tùy thuộc vào ngữ cảnh. Ví dụ, từ "bank" có thể có nghĩa là "ngân hàng" hoặc "bờ sông" [3].

Các khái niệm quan trọng trong lexical semantics bao gồm:

- **Đồng nghĩa (Synonymy):** Các từ có cùng nghĩa (ví dụ: "happy" và "joyful").
- **Trái nghĩa (Antonymy):** Các từ có nghĩa đối lập (ví dụ: "hot" và "cold").
- **Đa nghĩa (Polysemy):** Một từ có nhiều nghĩa liên quan (ví dụ: "star" có thể là ngôi sao trên trời hoặc người nổi tiếng).
- **Đồng âm khác nghĩa (Homonymy):** Các từ có cùng cách viết hoặc cách phát âm nhưng khác nghĩa và không liên quan (ví dụ: "bank" - ngân hàng và "bank" - bờ sông).
- **Quan hệ bao hàm (Hyponymy/Hypernymy):** Quan hệ giữa một khái niệm chung (hypernym) và các khái niệm cụ thể hơn (hyponyms). Ví dụ: "animal" là hypernym của "cat" và "dog" [4].

4.2.2. Khử mơ hồ nghĩa từ (Word Sense Disambiguation - WSD)

WSD là quá trình xác định nghĩa chính xác của một từ đa nghĩa trong một ngữ cảnh cụ thể. Đây là một nhiệm vụ quan trọng vì nó ảnh hưởng đến độ chính xác của các ứng dụng NLP khác như dịch máy, tìm kiếm thông tin và phân tích cảm xúc.

Các phương pháp WSD bao gồm:

- **Dựa trên từ điển (Dictionary-based):** Sử dụng các tài nguyên từ vựng như WordNet để tìm kiếm các định nghĩa và mối quan hệ giữa các từ.
- **Dựa trên ngữ liệu (Corpus-based):** Sử dụng các mô hình học máy được huấn luyện trên các ngữ liệu lớn để học cách phân biệt các nghĩa của từ dựa trên ngữ cảnh xung quanh [5].

4.2.3. Biểu diễn ý nghĩa từ (Word Embeddings)

Word embeddings là các biểu diễn vector dày đặc của từ trong một không gian đa chiều, trong đó các từ có ý nghĩa tương tự sẽ có vị trí gần nhau. Các mô hình word embedding phổ biến bao gồm Word2Vec, GloVe và FastText. Chúng giúp máy tính nắm bắt được mối quan hệ ngữ nghĩa giữa các từ một cách hiệu quả [6].

Ví dụ, trong không gian vector, vector của "king" - "man" + "woman" sẽ gần với vector của "queen".

4.3. Các mô hình ngữ nghĩa cơ bản

4.3.1. Mạng ngữ nghĩa (Semantic Networks)

Mạng ngữ nghĩa là các biểu đồ trong đó các nút đại diện cho các khái niệm và các cạnh đại diện cho mối quan hệ ngữ nghĩa giữa chúng. Ví dụ, trong một mạng ngữ nghĩa, có thể có một nút "dog" và một nút "animal", với một cạnh "is-a" nối từ "dog" đến "animal" [7].

4.3.2. Khung ngữ nghĩa (Semantic Frames)

Khung ngữ nghĩa là một cấu trúc dữ liệu đại diện cho một tình huống, sự kiện hoặc khái niệm cụ thể, bao gồm các vai trò ngữ nghĩa (semantic roles) và các thực thể liên quan. Ví dụ, khung "Mua" có thể bao gồm các vai trò như "Người mua", "Người bán", "Vật phẩm", "Giá cả" [8].

4.4. Ứng dụng của Semantic Processing I

- **Tìm kiếm ngữ nghĩa (Semantic Search):** Cho phép người dùng tìm kiếm thông tin dựa trên ý nghĩa của truy vấn thay vì chỉ dựa trên từ khóa khớp chính xác.
- **Hệ thống gợi ý (Recommendation Systems):** Hiểu sở thích của người dùng dựa trên ý nghĩa của các mặt hàng hoặc nội dung.
- **Phân tích cảm xúc (Sentiment Analysis):** Xác định thái độ, cảm xúc của người viết đối với một chủ đề cụ thể.
- **Tóm tắt văn bản (Text Summarization):** Tạo ra bản tóm tắt ngắn gọn nhưng vẫn giữ được ý nghĩa chính của văn bản gốc.

4.5. Kết luận Semantic Processing I

Semantic Processing I tập trung vào việc hiểu ý nghĩa của các từ riêng lẻ và mối quan hệ cơ bản giữa chúng. Các kỹ thuật như WSD và word embeddings là nền tảng để máy tính có thể nắm bắt được ý nghĩa từ vựng, mở đường cho việc phân tích ngữ nghĩa phức tạp hơn ở cấp độ câu và văn bản.

Tài liệu tham khảo

[1] GeeksforGeeks. (n.d.). *Understanding Semantic Analysis - NLP*. Retrieved from <https://www.geeksforgeeks.org/nlp/understanding-semantic-analysis-nlp/> [2] Coursera. (n.d.). *What Is Semantic Analysis?*. Retrieved from <https://www.coursera.org/articles/semantic-analysis> [3] Tutorialspoint. (n.d.). *Natural Language Processing - Semantic Analysis*. Retrieved from https://www.tutorialspoint.com/natural_language_processing/natural_language_processing_semantic_analysis.htm [4] Scaler Topics. (2023, January 12). *Elements of Semantic Analysis in NLP*. Retrieved from <https://www.scaler.com/topics/nlp/elements-of-semantic-analysis/> [5] IBM. (n.d.). *What Is NLP (Natural Language Processing)?*. Retrieved from <https://www.ibm.com/think/topics/natural-language-processing/> [6] Medium. (2024, January 16). *The Essential Role of Syntactic and Semantic Parsing in NLP*. Retrieved from <https://medium.com/@datailm/the-essential-role-of-syntactic-and-semantic-parsing-in-nlp-47b92118d9de> [7] ScienceDirect Topics. (n.d.). *Semantic Network*. Retrieved from <https://www.sciencedirect.com/topics/computer-science/semantic-network> [8] FrameNet. (n.d.). *FrameNet*. Retrieved from <https://framenet.icsi.berkeley.edu/fndrupal/>

5. NLP - Semantic Processing II

5.1. Giới thiệu về Semantic Processing II

Semantic Processing II tiếp tục khám phá các khía cạnh nâng cao của phân tích ngữ nghĩa, tập trung vào việc hiểu ý nghĩa ở cấp độ câu và văn bản. Trong khi Semantic Processing I đặt nền móng với ý nghĩa từ vựng, giai đoạn này đi sâu vào cách các từ kết hợp với nhau để tạo ra ý nghĩa phức tạp hơn, bao gồm cả các sắc thái và ngữ cảnh [1].

5.2. Các kỹ thuật nâng cao trong Semantic Processing

5.2.1. Nhận dạng thực thể có tên (Named Entity Recognition - NER)

NER là quá trình xác định và phân loại các thực thể có tên trong văn bản thành các danh mục được xác định trước như tên người, tổ chức, địa điểm, ngày tháng, số lượng, v.v. NER là một bước quan trọng để trích xuất thông tin có cấu trúc từ văn bản phi cấu trúc [2].

Ví dụ: Trong câu "Barack Obama sinh ra ở Honolulu vào ngày 4 tháng 8 năm 1961.", NER sẽ xác định "Barack Obama" là Tên người, "Honolulu" là Địa điểm, và "4 tháng 8 năm 1961" là Ngày tháng.

5.2.2. Trích xuất quan hệ (Relation Extraction)

Relation Extraction là quá trình xác định các mối quan hệ ngữ nghĩa giữa các thực thể có tên trong văn bản. Ví dụ, từ câu "Barack Obama là cựu Tổng thống Hoa Kỳ.", hệ thống có thể trích xuất mối quan hệ "là Tổng thống của" giữa "Barack Obama" và "Hoa Kỳ" [3].

Các phương pháp trích xuất quan hệ bao gồm:

- **Dựa trên quy tắc (Rule-based):** Sử dụng các mẫu (patterns) được định nghĩa trước để tìm kiếm các mối quan hệ.
- **Dựa trên học máy (Machine Learning-based):** Huấn luyện các mô hình để học cách nhận dạng các mối quan hệ từ dữ liệu đã gán nhãn.

5.2.3. Phân tích vai trò ngữ nghĩa (Semantic Role Labeling - SRL)

SRL là quá trình xác định các vai trò ngữ nghĩa (semantic roles) của các thành phần trong câu đối với một vị từ (predicate) cụ thể (thường là động từ). Các vai trò này bao gồm tác nhân (agent), đối tượng (patient), công cụ

(instrument), địa điểm (location), thời gian (time), v.v. [4].

Ví dụ: Trong câu "John (tác nhân) đã ăn quả táo (đối tượng) bằng cái nĩa (công cụ) trong bếp (địa điểm).", SRL sẽ gán nhãn các vai trò ngữ nghĩa cho từng thành phần.

5.2.4. Phân tích đồng tham chiếu (Coreference Resolution)

Coreference Resolution là quá trình xác định tất cả các biểu thức trong văn bản mà đề cập đến cùng một thực thể trong thế giới thực. Điều này bao gồm việc giải quyết các đại từ (pronouns) và các cụm danh từ (noun phrases) [5].

Ví dụ: Trong đoạn văn "John đi đến cửa hàng. Anh ấy mua một ít sữa.", Coreference Resolution sẽ xác định rằng "Anh ấy" đề cập đến "John".

5.2.5. Mô hình chủ đề (Topic Modeling)

Topic Modeling là một kỹ thuật học máy không giám sát được sử dụng để khám phá các chủ đề trừu tượng (abstract topics) xuất hiện trong một tập hợp các tài liệu. Mỗi chủ đề được biểu diễn bằng một tập hợp các từ có khả năng xuất hiện cùng nhau. Các thuật toán phổ biến bao gồm Latent Dirichlet Allocation (LDA) [6].

5.3. Các mô hình ngữ nghĩa hiện đại

5.3.1. Mô hình ngôn ngữ lớn (Large Language Models - LLMs)

Các mô hình ngôn ngữ lớn như BERT, GPT, T5 đã cách mạng hóa lĩnh vực NLP, bao gồm cả Semantic Processing. Các mô hình này được huấn luyện trên lượng lớn dữ liệu văn bản và có khả năng nắm bắt các mối quan hệ ngữ nghĩa phức tạp, ngữ cảnh và thậm chí cả ý định của người dùng [7].

LLMs sử dụng kiến trúc Transformer và cơ chế attention để xử lý văn bản, cho phép chúng hiểu được ý nghĩa của từ trong ngữ cảnh rộng hơn và tạo ra các biểu diễn ngữ nghĩa phong phú.

5.3.2. Biểu diễn ngữ nghĩa dựa trên đồ thị (Graph-based Semantic Representations)

Ngoài các biểu diễn vector, các biểu diễn ngữ nghĩa dựa trên đồ thị cũng được sử dụng để nắm bắt các mối quan hệ phức tạp giữa các khái niệm và thực thể. Knowledge Graphs (Đồ thị tri thức) là một ví dụ điển hình, nơi các thực thể và mối quan hệ của chúng được biểu diễn dưới dạng đồ thị [8].

5.4. Ứng dụng của Semantic Processing II

- **Hệ thống hỏi đáp (Question Answering Systems):** Trả lời các câu hỏi bằng cách hiểu ý nghĩa của câu hỏi và tìm kiếm thông tin liên quan trong cơ sở tri thức.
- **Chatbot và Trợ lý ảo:** Hiểu ý định của người dùng và cung cấp phản hồi phù hợp.
- **Phân tích hợp đồng và tài liệu pháp lý:** Trích xuất các điều khoản, điều kiện và nghĩa vụ từ các văn bản phức tạp.
- **Phát hiện tin tức giả mạo (Fake News Detection):** Phân tích ngữ nghĩa để xác định sự không nhất quán hoặc thông tin sai lệch.
- **Tạo văn bản (Text Generation):** Tạo ra văn bản có ý nghĩa và mạch lạc dựa trên một chủ đề hoặc ngữ cảnh nhất định.

5.5. Kết luận Semantic Processing II

Semantic Processing II mở rộng khả năng hiểu ý nghĩa của máy tính từ cấp độ từ vựng lên cấp độ câu và văn bản. Các kỹ thuật như NER, Relation Extraction, SRL và Coreference Resolution, cùng với sự phát triển của các mô hình ngôn ngữ lớn, đã giúp máy tính tiến gần hơn đến việc hiểu ngôn ngữ con người một cách toàn diện và sâu sắc.

Tài liệu tham khảo

[1] Datascientest. (2024, March 19). *Semantic Analysis: Definition and Use Cases in Natural Language Processing*. Retrieved from <https://datascientest.com/en/semantic-analysis-definition-and-use-cases-in-natural-language-processing> [2] GeeksforGeeks. (n.d.). *Named Entity Recognition (NER) in NLP*. Retrieved from <https://www.geeksforgeeks.org/named-entity-recognition-ner-in-nlp/> [3] IBM. (n.d.). *What is Relation Extraction?*. Retrieved from <https://www.ibm.com/docs/en/watson-knowledge-studio/2019.03?topic=overview-relation-extraction> [4] Wikipedia. (n.d.). *Semantic role labeling*. Retrieved from https://en.wikipedia.org/wiki/Semantic_role_labeling [5] Wikipedia. (n.d.). *Coreference resolution*. Retrieved from https://en.wikipedia.org/wiki/Coreference_resolution [6] GeeksforGeeks. (n.d.). *Topic Modeling in NLP*. Retrieved from <https://www.geeksforgeeks.org/topic-modeling-in-nlp/> [7] IBM. (n.d.). *What are Large Language Models (LLMs)?*. Retrieved from <https://www.ibm.com/topics/large-language-models> [8] Wikipedia. (n.d.). *Knowledge graph*. Retrieved from https://en.wikipedia.org/wiki/Knowledge_graph

6. Ticket Classification Project

6.1. Giới thiệu

Dự án phân loại ticket là một ứng dụng thực tế của Xử lý ngôn ngữ tự nhiên (NLP) trong lĩnh vực dịch vụ khách hàng và quản lý hỗ trợ. Mục tiêu của dự án này là xây dựng một hệ thống tự động phân loại các ticket hỗ trợ khách hàng (ví dụ: email, tin nhắn, yêu cầu từ khách hàng) vào các danh mục được xác định trước (ví dụ: "Lỗi kỹ thuật", "Yêu cầu tính năng", "Hóa đơn", "Hỗ trợ tài khoản").

Việc tự động hóa quá trình phân loại ticket giúp các tổ chức:

- Tăng hiệu quả:** Tự động định tuyến ticket đến đúng bộ phận hoặc nhân viên, giảm thời gian xử lý thủ công.
- Cải thiện trải nghiệm khách hàng:** Phản hồi nhanh hơn và chính xác hơn.
- Phân tích dữ liệu:** Cung cấp cái nhìn sâu sắc về các vấn đề phổ biến và xu hướng của khách hàng.

6.2. Mục tiêu dự án

- Hiểu quy trình xây dựng một hệ thống phân loại văn bản từ đầu đến cuối.
- Áp dụng các kỹ thuật Lexical Processing, Syntactic Processing và Semantic Processing đã học.
- Làm quen với các thư viện NLP và học máy phổ biến.
- Đánh giá hiệu suất của mô hình phân loại.

6.3. Dữ liệu

Để thực hiện dự án này, chúng ta cần một tập dữ liệu các ticket hỗ trợ đã được gán nhãn với các danh mục tương ứng. Nếu không có dữ liệu thực tế, có thể sử dụng các tập dữ liệu công khai hoặc tạo dữ liệu giả lập. Ví dụ về cấu trúc dữ liệu:

ID Ticket	Nội dung Ticket	Danh mục
001	Không thể đăng nhập vào tài khoản của tôi.	Hỗ trợ tài khoản
002	Lỗi khi thanh toán hóa đơn số 12345.	Hóa đơn
003	Ứng dụng bị treo khi mở tính năng X.	Lỗi kỹ thuật
004	Tôi muốn yêu cầu thêm tính năng báo cáo mới.	Yêu cầu tính năng

6.4. Các bước thực hiện dự án

6.4.1. Thu thập và tiền xử lý dữ liệu

1. **Thu thập dữ liệu:** Tải xuống hoặc tạo tập dữ liệu ticket. Chia dữ liệu thành tập huấn luyện (training set) và tập kiểm tra (test set).
2. **Tiền xử lý văn bản:**
 - **Làm sạch dữ liệu:** Loại bỏ ký tự đặc biệt, số, URL, HTML tags (nếu có).
 - **Chuyển đổi chữ thường:** Đưa tất cả văn bản về chữ thường.
 - **Tokenization:** Tách văn bản thành các từ hoặc cụm từ.
 - **Loại bỏ từ dừng (Stop Word Removal):** Xóa các từ phổ biến không mang nhiều ý nghĩa.
 - **Lemmatization/Stemming:** Đưa các từ về dạng gốc.

6.4.2. Biểu diễn văn bản (Feature Engineering)

Chuyển đổi văn bản đã tiền xử lý thành định dạng số mà mô hình học máy có thể hiểu được. Các phương pháp phổ biến:

1. **Bag-of-Words (BoW):** Tạo một vector đếm tần suất xuất hiện của mỗi từ trong văn bản.
2. **TF-IDF (Term Frequency-Inverse Document Frequency):** Đánh giá mức độ quan trọng của một từ trong văn bản so với toàn bộ tập dữ liệu.
3. **Word Embeddings (Word2Vec, GloVe, FastText):** Biểu diễn từ dưới dạng vector dày đặc, nắm bắt được ngữ nghĩa và mối quan hệ giữa các từ.
4. **Mô hình ngôn ngữ tiền huấn luyện (Pre-trained Language Models - PLMs):** Sử dụng các mô hình như BERT, RoBERTa, XLM-R để tạo ra các biểu diễn ngữ cảnh cho văn bản.

6.4.3. Xây dựng và huấn luyện mô hình

Chọn một thuật toán học máy hoặc học sâu để xây dựng mô hình phân loại. Các lựa chọn phổ biến:

1. **Học máy truyền thống:**
 - **Naive Bayes:** Đơn giản, hiệu quả cho phân loại văn bản.
 - **Support Vector Machine (SVM):** Hiệu quả với dữ liệu chiều cao.
 - **Logistic Regression:** Mô hình tuyến tính đơn giản.
2. **Học sâu:**
 - **Mạng nơ-ron hồi quy (Recurrent Neural Networks - RNN) / Long Short-Term Memory (LSTM):** Tốt cho dữ liệu chuỗi.
 - **Mạng nơ-ron tích chập (Convolutional Neural Networks - CNN):** Hiệu quả trong việc trích xuất đặc trưng cục bộ.
 - **Mô hình dựa trên Transformer (BERT, RoBERTa):** Đạt hiệu suất cao nhất hiện nay trong nhiều tác vụ NLP.

6.4.4. Đánh giá mô hình

Đánh giá hiệu suất của mô hình trên tập kiểm tra bằng các chỉ số:

- **Độ chính xác (Accuracy):** Tỷ lệ dự đoán đúng.
- **Độ chính xác (Precision):** Tỷ lệ các trường hợp dương tính được dự đoán đúng trong tổng số các trường hợp được dự đoán là dương tính.

- **Độ thu hồi (Recall):** Tỷ lệ các trường hợp dương tính được dự đoán đúng trong tổng số các trường hợp dương tính thực tế.
- **Điểm F1 (F1-Score):** Trung bình điều hòa của Precision và Recall.
- **Ma trận nhầm lẫn (Confusion Matrix):** Biểu đồ thể hiện số lượng dự đoán đúng và sai cho mỗi lớp.

6.5. Các công cụ và thư viện gợi ý

- **Python:** Ngôn ngữ lập trình chính.
- **NLTK, spaCy:** Để tiền xử lý văn bản.
- **scikit-learn:** Để xây dựng các mô hình học máy truyền thống và đánh giá.
- **TensorFlow, PyTorch, Keras:** Để xây dựng các mô hình học sâu.
- **Hugging Face Transformers:** Để sử dụng các mô hình ngôn ngữ tiền huấn luyện.

6.6. Mở rộng dự án (Tùy chọn)

- **Xử lý ngôn ngữ đa ngôn ngữ:** Mở rộng mô hình để phân loại ticket bằng nhiều ngôn ngữ khác nhau.
- **Phân tích cảm xúc:** Kết hợp phân loại ticket với phân tích cảm xúc để hiểu thái độ của khách hàng.
- **Hệ thống gợi ý phản hồi:** Sau khi phân loại, gợi ý các phản hồi tiêu chuẩn cho nhân viên hỗ trợ.
- **Giao diện người dùng:** Xây dựng một giao diện web đơn giản để người dùng có thể nhập ticket và xem kết quả phân loại.

6.7. Kết luận dự án

Dự án phân loại ticket là một cách tuyệt vời để áp dụng các kiến thức NLP đã học vào một vấn đề thực tế. Nó không chỉ củng cố các kỹ năng kỹ thuật mà còn giúp hiểu rõ hơn về quy trình phát triển một hệ thống NLP từ đầu đến cuối.

Buffer

Phần này được dành riêng cho các nội dung bổ sung, cập nhật hoặc các ghi chú khác không thuộc các chương chính của giáo trình. Nó có thể bao gồm:

- Các thuật toán NLP mới nổi.
- Các công cụ và thư viện NLP mới.
- Các nghiên cứu điển hình (case studies) hoặc ứng dụng thực tế khác.
- Câu hỏi thường gặp (FAQ) và giải đáp.
- Ghi chú về các phiên bản cập nhật của giáo trình.

Nội dung trong phần Buffer sẽ được cập nhật định kỳ để đảm bảo giáo trình luôn phản ánh những tiến bộ mới nhất trong lĩnh vực NLP.